# Тренажёр оператора ДДС города Москвы

**Сопроводительная документация**

Задача №9 Департамента по делам гражданской обороны, чрезвычайным ситуациям и пожарной безопасности города Москвы. Лидеры цифровой трансформации, 2026.

---

## 1. Назначение

Тренажёр готовит операторов дежурно-диспетчерских служб и Системы-112 к работе в боевой системе **ПОВ-112 (АРМ-112)**. Оба участка из ТЗ отрабатываются в интерфейсе, повторяющем боевой:

- **оператор 112** принимает учебный вызов: выясняет у заявителя обстоятельства, заполняет карточку происшествия, классифицирует его и оповещает службы;
- **диспетчер ДДС** получает поток карточек своей службы: принимает или мотивированно отклоняет, назначает бригаду, по докладам старшего ведёт статусы реагирования до завершения.

Преподаватель проводит занятия по группе, готовит учебные вызовы и видит аналитику. После каждого вызова курсант получает разбор с ценой каждой ошибки, прогноз своего результата и рекомендации — и то, и другое система потом проверяет фактом. Свободный текст курсанта читает модель и указывает расхождения с услышанным, с цитатами; преподаватель подтверждает их и ставит экспертную оценку рядом с автоматической.

Ключевая особенность решения — **тренажёр отличает выясненное от угаданного**. Раздел 3.3 объясняет, почему это главная метрика подготовки оператора.

---

## 2. Состав решения

| Компонент | Технология | Назначение |
|---|---|---|
| Веб-клиент | React 19, TypeScript, Vite | интерфейс АРМ-112 и учебный слой |
| Сервер приложения | Rust, axum, tokio | API, домен, оценка, фоновые задачи |
| Хранилище | PostgreSQL 16 | классификатор, вызовы, занятия, журналы, настройки |
| Языковая модель | GigaChat 3.1 10B-A1.8B на llama.cpp | подготовка учебных вызовов, правка по переписке, сводки, анализ текста курсанта |
| Голос | GigaAM v3 (распознавание) и TeraTTSv2 (синтез), ONNX на процессоре | разговор диспетчера ДДС со старшим бригады голосом |

| Компонент | Технология | Назначение |
|---|---|---|
| Сверка описания | кросс-энкодер OpenJEV (Qwen3.5, 2B или 4B), PyTorch на процессоре | сверка описания курсанта с фактами вызова, раздел 3.9 |

Все шесть компонентов разворачиваются на одной машине без выхода в интернет и без графического ускорителя — одной командой, раздел 7.7. Обоснование выбора — раздел 6.

Объём исходного кода: 15 848 строк Rust в 63 файлах, 5 673 строки TypeScript в 49 файлах, 28 миграций схемы базы.

---

## 3. Методы обработки данных

### 3.1. Классификация происшествия — детерминированная, без нейросети

Единый классификатор происшествий (ЕКП) — это таблица, где каждой комбинации признаков соответствует **ровно один** правильный ответ. Поэтому классификацию считает не модель, а прямой поиск по таблице:

```
ответы карты ──①──► признаки ──②──► позиция ЕКП ──③──► список оповещения
```

① Ответы опросной карты сопоставляются с признаками трёх уровней («где», «что именно», «уточнение»). ② По группе и признакам ищется позиция классификатора. Если незаполненный уровень признаков оставляет несколько позиций с разными исходами, система **не выбирает первую попавшуюся**, а называет варианты и просит уточнить — так же ведёт себя боевая система. ③ Позиция задаёт список оповещения. Службы, получающие лишь копию карточки (значения «карточка-112», «нет реагирования»), отделяются от реагирующих: оценка не должна штрафовать за то, что оператор их не вызвал.

В активной версии классификатора **1 283 позиции в 24 группах**, **134 593 строки матрицы оповещения**, 60 служб.

Такой выбор даёт воспроизводимость: эталон для учебного вызова не зависит от того, какая модель загружена и загружена ли вообще.

### 3.2. Опросные карты для всех типов происшествия

В выпадающем списке «Что случилось?» — **51 тип**, как в боевой системе (полный список передан экспертами в чате задачи). Опросная карта есть у **44** из них:

- **3 карты сняты с кадров боевой системы** (101 — пожар, 104 — газ, «Взрыв»): формулировки вопросов и вариантов дословные. Карта 101 снята по трём веткам — «Дом», «Улица» и «Транспорт»;
- **41 карта выведена из классификатора**: опросная карта боевой системы — это дерево признаков группы, и классификатор содержит его целиком. Подписи вопросов — заголовки столбцов классификатора, варианты — дословно из ячеек. Ничего не сочинено;

- **у 7 типов карты нет** («Внутренний звонок», «Нецелевой вызов», «Технический сбой» и др.): это виды обращений, а не происшествия, в классификаторе им не соответствует ни один признак. Интерфейс так и пишет, а не показывает пустую форму.

Карта **растёт по мере ответов**, как на кадрах боевой системы:

- варианты второго признака зависят от первого (`depends_on`): у «ДТП» одни, у «ДТП с пострадавшими» — другие; смена первого признака снимает неподходящие ответы на втором;
- вопрос целиком появляется только при нужном ответе (`show_when`): на пустом «Где» у пожара видны только «Где» и «Описание», после «Улица» — «Признак пожара», «Доступ», «Место происшествия», а «Описание правонарушения» — лишь после «Есть правонарушение».

Карты выводятся при каждом запуске сервера и при активации новой версии классификатора — поэтому смена версии не оставляет устаревших карт.

### 3.3. Оценка оператора 112 — три слоя

Разбор сравнивает три независимых слоя данных:

| Слой | Что это |
|---|---|
| **Скрытая истина** | что на самом деле произошло, заложено в сценарий |
| **Стенограмма** | что заявитель действительно сообщил в разговоре |
| **Карточка** | что оператор ввёл в поля |

Из сопоставления рождаются четыре вида замечаний с разным весом:

| Вид | Вес | Смысл |
|---|---|---|
| `guessed` | 1 | значение верное, но заявитель его не сообщал — **угадал** |
| `extra` | 1 | вызвана лишняя служба |
| `missing` | 2 | служба не оповещена |
| `wrong` | 3 | значение не совпало с эталоном |

Превышение норматива времени добавляет 2.

Замечание формулируется как последствие, а не как балл: не «−3 за поле „служба“», а «служба не оповещена — фактически не выехала».

Смысл метрики «угадал»: оператор, угадавший тип происшествия по первой фразе, в боевой обстановке ошибётся, как только вызов окажется нетипичным. На данных стенда доля угаданного составила **38 %** — то есть больше трети верных ответов курсанты не выясняли у заявителя.

### 3.4. Работа диспетчера ДДС: статусы, нормативы, бригада

**Статусы реагирования** идут строго по памятке ДДС: сначала «Принята» или «Не принята», затем «Начало реагирования» → «Прибытие» → «Проведение работ» → «Работы завершены» или «Отказ от выполнения работ». Порядок проверяется на сервере, а не только в интерфейсе. «Не принята» и

«Отказ» без комментария сервер не принимает: заказчик требует мотивированного отказа. Поля, которые заполнил оператор 112, диспетчер ДДС не редактирует — только свои статусы и комментарии к ним.

**Нормативы — по ответу заказчика в чате задачи (27.09.2026):**

| Норматив | Значение | Отсчёт |
|---|---|---|
| Открыть карточку | 30 с | с момента появления карточки в строке сообщений |
| Первая запись: статус и текст | 3 мин | см. ниже |

Открытие карточки фиксируется системной отметкой «Получена службой». Точка отсчёта трёх минут в ответе заказчика («3 минуты на открытие карточки и добавление первой записи») однозначно не закреплена; мы считаем от поступления карточки. Остальные временные показатели заказчик не определял: работы могут идти часами и днями.

**Статус карточки** не хранится как состояние конечного автомата, а **выводится** из состояния служб и прошедшего времени. Фоновая задача (тик 5 секунд) пересчитывает статусы и переводит карточки в «Не оповещено» (норматив открытия или первой записи истёк) и «Не завершено» (48 часов, памятка ДДС). Запись условная — по прежнему статусу, поэтому два экземпляра сервера не запишут переход дважды.

**Бригада.** По ответам заказчика бригаду диспетчер выбирает вручную, а сведения о ходе работ получает от старшего: тот звонит с докладом сам, или диспетчер сам звонит ему. В тренажёре живут оба варианта:

- этапы работ бригады наступают по шкале от момента назначения — это скрытая истина, как факты заявителя у оператора 112;
- старший докладывает о наступившем этапе с задержкой; диспетчер, который позвонил раньше, узнаёт раньше. Доклад называет только этап («прибыли на место») — обстановку на месте мы не придумываем.

Разбор диспетчера ДДС проверяет требование памятки «статусы по факту получения информации»:

| Замечание | Вес | Смысл |
|---|---|---|
| статус раньше доклада | 2 | «не по факту» — аналог «угадал» у оператора 112 |
| доклад без статуса | 2 | служба 112 и соседние ДДС не видят хода работ |
| принята, бригада не назначена | 2 | на место никто не выехал |
| статус позже доклада сверх норматива | 1 | в карточке устаревшая картина |
| карточка открыта позже 30 с | 1 | норматив заказчика |
| первая запись позже 3 мин или без текста | 1 | норматив заказчика |

**Что здесь — наше допущение, а не норматив заказчика.** Число учебных бригад (3), шкала этапов (выезд 20 с, путь 40 с, начало работ 20 с, работы 60 с), задержка доклада (25 с) и норматив обновления статуса после доклада (30 с) заказчик не называл. Шкала сжата под учебное занятие, одна

на все службы — заказчик сам попросил «универсальный алгоритм для всех». Всё вынесено в настройки и перечислено в `PROVENANCE.md` («Наши допущения») и `OPEN-QUESTIONS.md` (вопрос 18).

**Доклад вышестоящему начальнику.** Второй собеседник диспетчера ДДС по ответу заказчика (27.09): «голосовое общение ДДС с вышестоящим начальником и ДДС с руководителем бригады». Диспетчер звонит из карточки своей службы и докладывает; начальник переспрашивает о том, чего не услышал, — не больше трёх вопросов — и говорит «Принял». Говорить можно голосом или набирать текстом: без сервера речи звонок целиком идёт текстом.

Что ждут в докладе, в материалах не сказано. Наше допущение (`OPEN-QUESTIONS.md`, вопрос 22) — то, что диспетчер знает сам: что случилось, где (улица и дом), пострадавшие, кого ещё оповестили, какую бригаду направил и на каком она этапе по последнему полученному докладу. Начальник ничего сверх карточки не спрашивает и не сообщает.

Разбор доклада — отдельный блок в разборе попытки ДДС: по каждому сведению «доложено», «не доложено» или «доложено неверно» (например, «пострадавших нет», когда в карточке двое), с дословной фразой диспетчера. Балл правил бригады он не меняет, решение по нему — за преподавателем. Устройство то же, что у анализа ручного ввода (раздел 3.9): доложенное отмечает модель, но только с цитатой, и цитату проверяет код; без модели доложенное ищут ключевые слова. Вопрос модели с подсказкой («Пострадавших двое?» — цифра, слово из адреса) заменяется готовой формулировкой: начальник спрашивает, а не подсказывает.

На процессоре реплика модели — 17–48 с, в телефонном разговоре это недопустимо. Поэтому по умолчанию начальник переспрашивает по ключевым словам без паузы, а модель один раз разбирает доклад после «Принял», в фоне (около 20 с; до этого в разборе — ключевые слова с пометкой). Настройка `chief.live_model` включает модель в каждую реплику — для сервера с видеокартой. Замер — `backend/docs/замеры/доклад-начальнику.md`.

## 3.5. Прогноз результата и его проверка

Критерий экспертизы просит не прогноз, а **его проверку** — сравнение прогнозных значений с реальными. Поэтому устройство такое:

1. **Прогноз фиксируется до начала вызова** и задним числом не переписывается; факт проставляется после разбора. Точность показывается только по фактически сделанным прогнозам.
2. **Модель — гребневая регрессия**, а не нейросеть: данных мало, сложная модель переобучится, а на разборе нужно показать, из чего сложился прогноз. Признаки — по последним разборам курсанта: средний балл, тренд, доля угаданного, доля превышений норматива, опыт, средний балл на той же группе классификатора. Коэффициенты считаются решением нормальных уравнений, без внешних библиотек.
3. **Рядом всегда базовая линия** — средний балл курсанта. Пока пар «прогноз — факт» меньше 30, модель не обучается и прогноз делает базовая линия; при истории меньше 3 разборов прогноз помечается недостоверным.
4. Достоверность — средняя абсолютная ошибка, доля попаданий в допуск (по умолчанию ±10 баллов) и та же ошибка у базовой линии: видно, стоит ли модель своих сложностей.

Курсант видит свой прогноз с разложением по признакам в разборе, преподаватель — достоверность прогноза по группе в аналитике.

### 3.6. Рекомендации курсанту и проверка их исполнения

Рекомендация сама по себе — декларация, поэтому проверяется так же, как прогноз. После разбора система ищет **повторяющиеся** ошибки: одно и то же поле с тем же видом замечания в последних разборах. Текст рекомендации собирается только из замечаний разбора — подпись поля плюс заготовка по виду ошибки, — модель его не пишет.

Рекомендация фиксируется с временем. В первом следующем разборе, где ошибка могла повториться, ставится вердикт: ушла или нет. Доля сработавших — измеренная величина, и рядом базовая линия: как часто та же повторяющаяся ошибка уходит сама, без рекомендации.

Пороги — **наше допущение** (`OPEN-QUESTIONS.md`, вопрос 19): окно 5 разборов, повтор не меньше 2 раз, открытых рекомендаций не больше 3, о доле судим не раньше 5 проверок. Сравнение с базовой линией строже к рекомендациям, чем к ней самой: рекомендации достаются самым частым ошибкам. На экране это сказано.

### 3.7. Языковая модель — только текст

Модель отвечает за то, что нельзя посчитать: черновики учебных вызовов (первая фраза заявителя, его ответы на вопросы), правку вызова по переписке с преподавателем, словесные сводки по группе. **Эталон для оценки она не считает никогда** — его считает классификатор. Ответы заявителя подготовлены заранее и выверены преподавателем — пока курсант ведёт вызов, модель их не сочиняет. Одно исключение — свободный вопрос заявителю (раздел 3.11): модель понимает, про какой из заготовленных фактов спросили, и выбирает его из закрытого списка; ответ заявителя и тогда — записанный в сценарии. После сохранения модель ещё в фоновой очереди читает свободный текст курсанта (раздел 3.9). Разбор правил курсант видит сразу, анализ модели приходит следом.

При подготовке учебного вызова конвейер устроен так:

1. признаки выбираются из **закрытого словаря** опросной карты;
2. ответы, которых нет в словаре, отбрасываются;
3. классификатор считает эталон;
4. если он жалуется (например, «уточните признак второго уровня»), его жалоба возвращается модели как замечание, и шаг повторяется;
5. только после этого модель пишет текст легенды и скрытых фактов.

Ответ модели ограничен **схемой JSON на уровне декодирования** (`response_format: json_schema`): движок отбрасывает токены, нарушающие схему, поэтому структурно неверный ответ невозможен.

**Где работает модель.** Сервер приложения обращается к ней по протоколу, совместимому с OpenAI API; адрес задаётся переменной `ML_BASE_URL`. В поставке это локальный llama.cpp на той же машине — внешних обращений нет, данные никуда не уходят. Тот же адрес можно направить на другой совместимый сервер (vLLM, Ollama) во внутреннем контуре, не меняя кода. При развёртывании через

`deploy/up.sh` достаточно указать `ML_BASE_URL` в `deploy/.env` — тогда свой контейнер модели не поднимается.

### 3.8. Исходные данные

Все данные, на которых работает тренажёр, взяты из материалов задачи и ответов экспертов. Их происхождение построчно зафиксировано в `PROVENANCE.md`:

- **ЕКП** — файлы классификатора двух версий (v046_11 от 15.11.2024 и v046_24 с корректировкой МВД и Департамента), импортированы целиком;
- **учебные вызовы** — 96 обращений, разобранных из 32 бумажных билетов; у всех 96 разобран телефон, у 57 — ФИО заявителя, у 25 — скрытый адрес. Из них готовятся учебные вызовы (раздел 4.6);
- **интерфейс** — снят по скриншотам боевой системы, сопоставление кадров описано в `frontend/SCENARIOS.md`; полный список типов происшествия, ветки карты 101 и справочник служб — по материалам, переданным экспертами в чате задачи.

Где данных заказчика не хватило, параметр вынесен в настройки и помечен как наше допущение (`PROVENANCE.md`, «Наши допущения»). Синтетических данных, выданных за данные заказчика, в поставке нет.

### 3.9. Нейросетевой анализ ручного ввода и экспертная оценка

ТЗ требует оценки «в том числе на основе анализа ручного ввода текста», «на основе нейросетевого анализа» и просмотра результатов как «автоматическая оценка И экспертная оценка». Всё, что проверяется сравнением, — признаки, адрес, службы, статусы, время — проверяют правила (разделы 3.3, 3.4). Правила не умеют читать свободный текст; это делает модель.

**Что читает модель.**

| Попытка | Текст курсанта | С чем сверяется |
|---|---|---|
| Оператор 112 | «Описание со слов заявителя», описательный адрес | реплики заявителя из стенограммы вызова |
| Диспетчер ДДС | комментарии к статусам реагирования | описание из карточки 112 и полученные доклады бригады |

Анализ ставится в очередь при сохранении карточки 112 и при закрывающем статусе ДДС («Работы завершены», «Отказ от выполнения работ», «Не принята»).

**Как устроен запрос.** Модель не ищет расхождения сама — модель такого размера их пропускает: на пробном вызове она не заметила «горит баня» вместо «горит крыша дома». Вместо этого она разбирает текст курсанта по утверждениям и про каждое отвечает: подтверждается, противоречит или заявитель этого не сообщал; отдельно — что существенное заявитель сказал, а в тексте нет. Вид замечания из вердикта выводит код. Ответ ограничен схемой JSON на уровне декодирования.

**Каждое замечание подтверждено цитатой, и цитата проверяется кодом.** Фрагмент текста курсанта ищется в его тексте, фрагмент услышанного — в стенограмме или докладах (без учёта

регистра, «ё» и знаков препинания). Не нашлась цитата — замечание отбрасывается, и число отброшенных показывается преподавателю. Так модель не может приписать курсанту слова, которых он не писал, или заявителю — которых тот не говорил.

**Балл модель не меняет.** Замечания стоят в разборе отдельным блоком «Анализ текста (нейросеть)» со статусом (готовится, готов, модель недоступна), рядом с баллом правил. Преподаватель подтверждает или отклоняет каждое замечание. Модели нет (`ML_PROVIDER=mock`) — анализ честно помечается «модель недоступна», а не выдаёт пустой список, похожий на «замечаний нет». Подняли модель — преподаватель повторяет анализ кнопкой, курсанту проходить вызов заново не нужно.

**Экспертная оценка.** В карточке, открытой из журнала, преподаватель видит все попытки по ней — вызов 112 и работу каждой службы ДДС — и ставит экспертный балл 0–100 с комментарием. Автоматический балл при этом не переписывается: оба хранятся и показываются рядом, курсант видит оба и комментарий. Каждая оценка и её изменение пишутся в журнал действий (`grade.override`) вместе с автоматическим и прежним баллом, вердикты по замечаниям модели — тоже (`analysis.verdict`). Экспертный балл есть в отчёте по занятию (JSON и CSV) и в отчёте по группе. Администратор экспертную оценку не ставит: ТЗ запрещает ему вмешиваться в оценки, и мы не даём ему этого вовсе.

**Проверено.** Код вокруг модели — очередь, проверка цитат, хранение, права, аудит — покрыт проверками с подставной моделью. На настоящей модели (GigaChat 3.1 10B-A1.8B, llama.cpp, 6 потоков) проверено на нарочно испорченном описании вызова «горит крыша частного дома»: «Горит баня на участке, есть пострадавший. Дом газифицирован.» Модель нашла все четыре расхождения — баню вместо крыши дома, пострадавшего при «пострадавших нет», газификацию, о которой заявитель не говорил, и незаписанное «пламя видно». Ответ занимает **26–33 секунды** на процессоре. **Чего не проверяли:** согласие модели с экспертами на выборке вызовов — такой выборки у нас нет. Вид замечания («не записано» или «противоречие») модель от прогона к прогону путает, суть — нет; поэтому решение по каждому замечанию за преподавателем.

**На процессоре описание 112 сверяет кросс-энкодер.** Генеративная модель на процессоре не только медленна, но и плохо видит упущенное: на проверочном наборе (66 пар «описание — факт», три учебных вызова) GigaChat в 16 случаях из 26 назвал подтверждённым факт, о котором описание молчит. Кросс-энкодер OpenJEV решает ту же задачу как NLI — описание посылкой, факт вызова гипотезой, ответ «подтверждает / противоречит / молчит» — одним проходом, без генерации, одинаково при повторе. Сервер — `nli/server.py`, адрес `NLI_BASE_URL`; нет его — сверяет языковая модель, как описано выше. Выбор — настройка `analysis.engine` (авто, только кросс-энкодер, только языковая модель).

Кросс-энкодеру нужны факты утверждениями: «Нет, дом не газифицирован.» он читает как отрицание («Нет,»), и точность на сырых ответах заметно ниже. Поэтому при подготовке вызова языковая модель в очереди переписывает ответы заявителя и первую фразу утверждениями («Дом не газифицирован»), а преподаватель видит и правит их в разделе подготовки вызовов, рядом с ответами. Сверяются только факты, которые курсант слышал: легенда и ответы на заданные им вопросы.

| сверка на процессоре | верно | ложных «противоречит» | с на описание |
|---|---|---|---|
| OpenJEV 4B, утверждения готовит GigaChat | 45 из 49 (92 %) | 1 | 3,4 |
| OpenJEV 2B, утверждения готовит GigaChat | 39 из 49 (80 %) | 5 | 1,4 |
| GigaChat 3.1 (66 пар, та же постановка) | 48 из 66 (73 %) | 1 | 10,4 |

Чекпоинт по умолчанию — 2B: 9 ГБ памяти против 18 ГБ у 4B, а на машине ТЗ (32 ГБ) рядом ещё языковая модель и база. Где память есть, 4B точнее: ложных «противоречит» впятеро меньше. «Добавлено от себя» кросс-энкодер не ищет — это обратное направление, на наборе оно не мерилось, и это остаётся языковой модели. Комментарии диспетчера ДДС сверять с фактами нечего — их всегда читает языковая модель. Подробно — `backend/docs/замеры/ОПИСАНИЯ.md`.

### 3.10. Голос: распознавание и синтез на процессоре

По ответу заказчика (чат, 27.09.2026) голосом диспетчер ДДС говорит со старшим бригады и с вышестоящим начальником; физический IP-телефон не обязателен, достаточно программной эмуляции. Голос заявителя 112 на этапе MVP исключён, «но вы можете его сделать — это будет плюсом» — сделан, раздел 3.11.

**Что сделано.** Разговор диспетчера со старшим бригады:

1. Диспетчер нажимает «Сказать голосом» и говорит в микрофон; браузер пересчитывает запись в WAV 16 кГц моно.
2. Реплика распознаётся (`POST /api/voice/asr`) и уходит вместе со звонком старшему; сказанное сохраняется в разговоре — преподаватель видит не только факт звонка, но и что курсант сказал.
3. Ответ старшего и его входящие доклады озвучиваются (`POST /api/voice/tts`), текст остаётся на экране. Звук можно выключить переключателем в панели бригады.

**Модели.** Распознавание — GigaAM v3 e2e RNNT (сразу с пунктуацией), синтез — TeraTTSv2 с готовыми голосами из поставки модели: старший бригады и начальник звучат разными голосами. Никого не клонируем. Обе модели в ONNX, работают на процессоре, видеокарта не нужна.

**Что говорит собеседник, решает движок тренажёра**, а не модель: текст доклада называет только этап работ (раздел 3.4). Модель голоса лишь произносит его. Поэтому голос не добавляет выдуманной обстановки и не меняет разбор: оценка ДДС по-прежнему считается по тому, когда диспетчер узнал об этапе и когда поставил статус.

**Скорость** (замер — `backend/docs/замеры/ГОЛОС.md`, 4 потока, машина под нагрузкой): синтез фразы доклада — 0,5–0,7 с на 3–5 с звука, распознавание реплики — 0,2–0,3 с. Повторная фраза берётся из кэша.

**Без голоса всё работает.** Сервер голоса — отдельный процесс; не подключён — `GET /api/voice/status` отвечает «нет», кнопки «Сказать голосом» нет, разговор идёт текстом, как раньше.

**Чего не сделано.** Точность распознавания на живой речи в шуме не мерили — только на синтезированных фразах.

### 3.11. Разговор оператора 112 с заявителем: своими словами и голосом

Заказчик (чат, 27.09.2026): «Диалог с заявителем исключён на этапе MVP, но вы можете его сделать — это будет плюсом». Сделан.

**Как спрашивает курсант.** В панели обучающегося два режима: «Из списка» — готовые вопросы кнопками, как раньше, и «Своими словами» — поле ввода и кнопка «Голосом». Сказанное распознаётся тем же сервером голоса (раздел 3.10) и уходит как напечатанный вопрос.

**Как тренажёр понимает вопрос.** Задача закрытая: вопрос либо про один из скрытых фактов вызова, либо ни про какой. Модель не сочиняет ответ — она выбирает факт из перечисления, заданного схемой JSON (`LabelScorer`, `POST /api/sessions/{id}/ask-free`). Заявитель отвечает записанным в сценарии; понятый вопрос засчитывается как выясненный, ровно как нажатая кнопка, и разбор «выяснил или угадал» не меняется. Вопрос ни про что — заявитель переспрашивает («Не поняла вас, повторите») и ничего не выдумывает. В стенограмме — дословно то, что сказал курсант: по ней видно, как он спрашивал. Нет модели — вопрос понимается по совпадению слов; хуже, но разговор не встаёт.

**Голос заявителя.** Первая фраза и ответы звучат голосом заявителя — мужским или женским по отчеству из сценария (стили TeraTTSv2 из поставки модели, `ru_m1` и `ru_f1`). Переключатель «звук» — в шапке панели. Сервера голоса нет — всё текстом, как раньше.

**Замер** (`backend/docs/замеры/СВОБОДНЫЙ-ВОПРОС.md`, 34 вопроса на двух вызовах, 7 — нарочно ни про какой факт):

| модель | понят верно | «нечего отвечать» | медиана |
|---|---|---|---|
| ЦП: GigaChat 3.1, 6 потоков | 27 из 27 | 5 из 7 | 1,74 с |
| GPU: Qwen3.8-27B, RTX 4090 | 27 из 27 | 6 из 7 | 0,35 с |

На процессоре вопрос не по делу в двух случаях из семи получает ответ на ближайший факт, и этот факт засчитывается как выясненный, хотя спросили не про него. В стенограмме это видно: там дословный вопрос курсанта рядом с ответом заявителя, и преподаватель может поправить оценку экспертной (раздел 3.9). Синтез ответа заявителя — 0,4–0,5 с, распознавание вопроса — около 0,5 с.

**Чего не сделано.** Уточняющие вопросы, на которые у заявителя в сценарии нет факта («на каком этаже?», если этажа в сценарии нет), получают «не понял», а не правдоподобный ответ: выдумывать сведения заявителю модель не даём.

---

## 4. Функциональная архитектура

### 4.1. Роли

| Роль | Доступ |
|---|---|
| **Курсант** | |

| Роль | Доступ |
|---|---|
| | учебные вызовы, карточки своей службы, своя история, разбор, прогноз, рекомендации, свои автоматическая и экспертная оценки |
| **Преподаватель** | занятия, подготовка вызовов, группы, аналитика по группе, экспертная оценка попыток и вердикты по замечаниям модели |
| **Администратор** | версии классификатора, учётные записи (заведение, отключение, удаление с резервной копией), настройки, системные журналы; оценки видит, но не ставит |

Разграничение проверяется на сервере при каждом запросе; интерфейс скрывает недоступные разделы, но не является средством защиты.

### 4.2. Оператор 112

```
вход → журнал происшествий → учебный вызов
                                  │
              разговор с заявителем ⟷ заполнение карточки 112
                                  │
                        классификация → список оповещения
                                  │
                   разбор: оценка, прогноз, рекомендации
```

Курсант задаёт заявителю вопросы; ответ помечает факт выясненным — на этом держится разбор «узнал или угадал». Ввод в карточку уходит на сервер пакетами; правки в пределах одного окна **сливаются вглубь**, а не затирают друг друга. При обрыве сети пакет повторяется.

### 4.3. Диспетчер ДДС

Сохранённая оператором 112 карточка приходит в журнал каждой службы из списка оповещения. Диспетчер работает с несколькими карточками одновременно, как в текущей работе: пока он занят одной, время идёт и у ожидающих.

```
карточка в строке сообщений ─(30 с)─► открыта ─(3 мин)─► первая запись
      │                                                          │
      │                          «Принята» ─► назначить бригаду
      │                                              │
      │                 доклады старшего / звонок старшему
      │                                              │
      └──► «Не принята» с причиной     статусы по факту ─► «Работы завершены»
                                                     │
                                                разбор ДДС
```

Звонок старшему и входящие доклады приходят в карточку ДДС текстом, а при подключённом голосе — ещё и голосом: диспетчер говорит в микрофон, ответы старшего озвучиваются (раздел 3.10). Рядом — звонок вышестоящему начальнику с докладом по карточке (раздел 3.4).

### 4.4. Занятие преподавателя

Порядок — из ТЗ (§10, «Проведение практического занятия»): преподаватель создаёт занятие для группы, выбирает режим и категории происшествий под тему, запускает, следит за ходом и завершает в любой момент.

| Режим | Что получает группа |
|---|---|
| **Приём вызова (112)** | учебные вызовы по выбранным категориям; пока идёт занятие, курсант видит только их |
| **Работа ДДС** | карточки по службам курсантов — созданные системой, заполненные курсантами на занятиях 112 или вперемешку; до 5 карточек на службу, в случайном порядке |

В режиме ДДС карточки занятия **поступают потоком**: с интервалом, который задаёт преподаватель при создании занятия, — а не все сразу. Ход занятия виден по каждому курсанту: сколько взято, сколько доведено до разбора, средний балл. При завершении недоработанные вызовы закрываются.

**Вид занятия.** Кроме обычного, преподаватель собирает марафон или блиц — на том же механизме занятий (группа, запуск, ход, завершение), отличаются только правила:

| Вид | Что это | Правила |
|---|---|---|
| **Марафон** | экзамен на 5–10 вызовов приёма 112 | вызовы выбирает преподаватель (в своём порядке) или система по категориям; курсант идёт строго по порядку, у каждого вызова одна попытка; разбора, рекомендаций и балла между вызовами нет — они открываются после последнего вызова или по завершении занятия; обрыв и F5 продолжают тот же вызов |
| **Блиц** | серия из 3–10 коротких заданий на один сегмент карточки | сегмент — адрес, тип происшествия с опросной картой или службы; у ДДС — статусы по докладам бригады. Разбор — сразу после каждого задания, в балл идут только поля сегмента, время не оценивается |

Новой оценки ни марафон, ни блиц не вводят: берётся тот же разбор (раздел 3.3), блиц лишь ограничивает его сегментом, марафон — откладывает показ. В базе разбор хранится полным, поэтому отчёты преподавателя видят карточку целиком.

**Итоговый протокол** (`GET /api/lessons/{id}/protocol`) — по каждому курсанту: каждый вызов, балл (в блице — по сегменту), время, грубые ошибки, экспертная оценка; средний балл и общее время. Грубыми считаем неверное значение в любом поле и пропущенную службу или пропущенный тип происшествия — от них зависит, приедет ли нужная служба. Это наше допущение: в материалах задачи грубые ошибки не перечислены. Преподаватель видит протокол сразу и из него открывает карточку каждого вызова с разбором и экспертной оценкой; курсант — только свою строку, в марафоне — после последнего вызова.

Допущения по видам занятия: марафон — только у приёма вызова (у ДДС карточки и так идут потоком); нижняя граница блица — 3 задания; «пострадавшие» относятся к сегменту «тип происшествия».

### 4.5. Учётные записи

Администратор заводит, отключает и удаляет учётные записи курсантов, преподавателей и администраторов. ТЗ запрещает удалять критически важные данные без резервного копирования, поэтому удаление устроено так:

- запись **без истории** (завели и ни разу не вошли) стирается сразу;
- запись **с историей** сначала копируется в таблицу `user_backups` (учётные данные, группы, попытки с баллами), затем обезличивается: ФИО и логин заменяются, вход закрыт, из групп человек убран. Оценки, карточки и журнал действий остаются читаемыми;
- свою запись и последнего администратора удалить нельзя. Каждое удаление пишется в журнал действий (`user.delete`).

### 4.6. Подготовка учебных вызовов

Преподаватель запускает подготовку вызовов из билетов (конвейер раздела 3.7) и доводит каждый перепиской с моделью: «поменяй ФИО», «добавь, что из мусоропровода идёт пламя», «сделай первую фразу короче». Модель отвечает репликой и правкой; правка применяется к вызову, эталон пересчитывается классификатором. В переписке показывается, что **фактически** изменилось, — по сравнению вызова до и после, а не со слов модели. Сыгранные факты не удаляются, а снимаются с учёта, чтобы не ломать уже пройденные разборы.

Рядом с ответами заявителя преподаватель видит **утверждения** — те же ответы, переписанные моделью в повествовательную форму («Дом не газифицирован» вместо «Нет, дом не газифицирован»). По ним кросс-энкодер сверяет описание курсанта (раздел 3.9). Утверждения можно поправить вручную или подготовить заново; правка ответа сбрасывает его утверждение, и модель готовит новое в очереди.

Готовый вызов преподаватель утверждает — до утверждения курсанты его не видят. **Преподаватель — конечный валидатор**, как и просит заказчик.

Как правки преподавателя влияют на модель — ровно так: переписка по вызову сохраняется, и последние ходы подаются модели в контекст при следующей правке того же вызова, поэтому «нет, короче» имеет смысл. Весов модели правки не меняют, и на подготовку других вызовов не переносятся. Дообучения модели на правках преподавателя в поставке нет — как это должно выглядеть, заказчик пока не определил.

### 4.7. Аналитика

Диаграммы (тепловая карта ошибок, динамика, воронка, виды замечаний) строятся из статистики занятий средствами SVG, без сторонних библиотек. Там же — достоверность прогноза и доля сработавших рекомендаций по группе, рядом с базовыми линиями. Словесную сводку по группе формулирует модель — но **числа в неё подаются уже посчитанными**, в виде именованных агрегатов.

### 4.8. Настраиваемые параметры

Нормативы, параметры прогноза, рекомендаций и шкалы бригады хранятся в таблице настроек, а не в коде. Администратор меняет их через API (`PATCH /api/settings/{key}`); у каждого параметра есть допустимые пределы, значение вне их сервер отклоняет.

---

## 5. Компонентная архитектура

### 5.1. Сервер

```
api/        HTTP-обработчики, схема OpenAPI
domain/     классификатор, статусы, оценка, бригада, прогноз, рекомендации
ingest/     импорт классификатора и билетов, вывод опросных карт
reports/    отчёты, прогноз и рекомендации над данными базы
jobs/       фоновые задачи: сторож нормативов, доклады бригад, очередь модели
ml/         адаптеры моделей: HTTP-сервер модели и заглушка
```

Доменный слой не знает ни о HTTP, ни о моделях: классификатор, оценка, разбор ДДС, прогноз и рекомендации — чистые функции над данными. Поэтому все **323 серверные проверки** выполняются без поднятия модели; там, где важен ответ модели, её заменяет подставная.

Описание API машиночитаемо (OpenAPI, utoipa). Отдельная проверка читает список маршрутов из исходного кода и **падает при расхождении** со схемой.

### 5.2. Клиент

Слоистая раскладка (Feature-Sliced Design): `shared` → `entities` → `widgets` → `pages`. Состояние — zustand, стили — модули SCSS, маршрутизация — HashRouter (стенд отдаётся статикой без настройки переписывания путей).

Канал событий WebSocket с переподключением по возрастающей задержке. Канал — **ускорение, а не источник истины**: при его отказе интерфейс продолжает работать на обычных запросах.

### 5.3. Сервер модели

llama.cpp в режиме сервера, совместимого с OpenAI API. Подробности — `backend/docs/MODEL-SERVER.md`.

### 5.3а. Сервер сверки описания (кросс-энкодер)

`nli/server.py` — небольшой сервер на Python (FastAPI, PyTorch на процессоре): `POST /nli {premise, hypotheses}` → вероятности «противоречит / следует / молчит» по каждой гипотезе, `GET /health`. Сервер приложения ходит к нему по адресу `NLI_BASE_URL` через адаптер `ml/nli.rs`; клиенту он не виден. Чекпоинт — `NLI_MODEL_DIR` (`qwen3.5-2b-nli-v5` или `qwen3.5-4b-nli-v5` из

`AlexWortega/openjev`). Считает в float32: bfloat16 на процессоре без его поддержки вчетверо медленнее, а экспорт гибридной модели в ONNX штатным экспортёром не проходит.

### 5.4. Сервер голоса

`voice/server.py` — небольшой сервер на Python (FastAPI, onnxruntime): `POST /asr` (WAV → текст), `POST /tts` (текст и роль собеседника → WAV), `GET /health`. Сервер приложения ходит к нему по адресу `VOICE_BASE_URL` через адаптеры `ml/voice.rs`; клиенту он не виден. Синтезированные фразы кэшируются на диске по хешу текста и голоса. Числа и сокращения адреса («№», «ул.», «д. 28») сервер разворачивает в слова сам: рантайм синтеза пропускал число перед точкой, и в адресе терялся номер дома.

---

## 6. Условия и ограничения

### 6.1. Целевой стенд

Процессор Intel Core i7 или Xeon, не менее 6 ядер; 32 ГБ оперативной памяти; **графический ускоритель не предусмотрен**. Это задано системными требованиями, и из этого следует весь выбор в разделе 3.

### 6.2. Что из этого следует

Модель на процессоре — узкое место. Выбрана **GigaChat 3.1 10B-A1.8B**: из десяти миллиардов параметров на каждом токене работают 1,8 миллиарда (архитектура со смесью экспертов, 64 эксперта, используются 4). Скорость на процессоре определяется активными параметрами, а не общим размером, поэтому модель отвечает как небольшая, а знает как крупная. Лицензия MIT.

Дополнительно включено **спекулятивное декодирование на блоке MTP** (multi-token prediction), встроенном в модель. Поддержки этого режима для данной архитектуры в llama.cpp не было — она добавлена двумя патчами, которые приложены к поставке (`backend/docs/mtp-*.patch`).

Измеренный результат на 6 потоках: **10,3 → 14,8 токенов в секунду, прирост 44 %**. Существенно, что `--spec-draft-n-max 1`: при значении по умолчанию 3 проверка отбрасывала большую часть черновика (доля принятых токенов 30 %), при 1 — принимается 73 %.

**Оговорки к замеру.** Мерили на AMD EPYC 7532 с **восемью каналами памяти**; ограничены были потоки (6), но не каналы. Генерация на процессоре упирается в пропускную способность памяти, а не в ядра, поэтому это **потолок, а не пол**: на настольном i7 с двухканальной памятью скорость будет ниже. На такой машине мы не мерили и цифру не называем (`OPEN-QUESTIONS.md`, вопрос 11). Сравнивались два прогона при одинаковой нагрузке, а не серия: порядок величины достоверен, вторая значащая цифра — нет.

Скорость модели почти не влияет на нормативы ТЗ: пока курсант ведёт вызов, модель вызывается только на свободный вопрос заявителю — ответ в несколько токенов, медиана 1,7 с на процессоре (раздел 3.11); кнопки вопросов работают без неё. Подготовка вызовов, сводки и анализ текста после

сохранения идут в фоновой очереди. Очередь одна: если группа из двадцати курсантов сохранит карточки разом, анализ последнего придёт через двадцать ответов модели. Разбор правил от этого не зависит — он приходит сразу.

### 6.2a. Профиль GPU — тот же тренажёр с моделью покрупнее

Если заказчик выделит видеокарту (в чате 23.09: «могут, если нужно будет»), меняется одна переменная — `ML_BASE_URL`. Сборка, база, интерфейс и все правила оценки те же. Проверено на одной RTX 4090 (24 ГБ): **Qwen3.8-27B** в квантовании INT4 (W4A16, `RedHatAI/Qwen3.8-27B-INT4`) под vLLM 0.30, скрипт запуска и флаги — `deploy/gpu/start-vllm.sh`. Лицензия модели — Apache 2.0.

Замеры 28.09 на наших запросах, модель одна на машине:

| **задача** | **ЦП: GigaChat 3.1** | **GPU: Qwen3.8-27B** |
|---|---|---|
| подготовка вызова по билету (`try_generate 3 1`) | 94 с | 7 с |
| анализ описания курсанта с цитатами | 26–33 с | 7,6 с |
| разбор доклада начальнику после «Принял» | 20,8 с | 5,4 с |
| сверка описания с фактами, 66 пар (`backend/docs/замеры/ОПИСАНИЯ.md`) | 73 %, 10,4 с на описание | 92 %, 1,1 с на описание |

На GPU реплика начальника укладывается в секунды, поэтому там включается модель в каждой реплике (`chief.live_model = 1`); на процессоре начальник спрашивает по ключевым словам, а модель разбирает доклад один раз в конце.

### 6.3. Требования ТЗ к производительности — измерено

Замер 28.09.2026 на release-сборке. Сервер тренажёра и PostgreSQL вместе ограничены **6 физическими ядрами и 32 ГБ** — как одна машина из требований ТЗ к серверу. Процессор — AMD EPYC 7532, **это не машина заказчика**: память у него восьмиканальная, у настольного i7 — нет. Языковая модель выключена: во время занятия курсанта она нужна только для свободного вопроса заявителю (раздел 3.11), нагрузочный прогон спрашивает кнопками. Методика, сырые данные и скрипт — `backend/docs/замеры/НАГРУЗКА.md`.

| **Требование ТЗ (§7)** | **Измерено** | **Условия** |
|---|---|---|
| отклик интерфейса ≤ 2 с при нагрузке до 100 пользователей | максимум 0,69 с, p99 0,18 с; без пауз между действиями (1783 запроса/с) — максимум 0,61 с, p99 0,27 с; ошибок 0 | 80 курсантов и 20 преподавателей, 60 с, пауза 1 с между действиями |
| не менее 20 одновременных сессий | 50 вызовов, начатых в одну секунду, — все дошли до разбора, по 0,62–0,64 с на вызов целиком; 80 разом — все, до 2,2 с на вызов, самый долгий запрос 0,82 с | вызов целиком: вход, начало, пять вопросов, правка, сохранение |
| | правки, внесённые без сети, в базе через 0,1 с после её возврата; канал | |

| Требование ТЗ (§7) | Измерено | Условия |
|---|---|---|
| сбой сети до 30 с — восстановление без потери данных | событий открыт через 0,1 с; та же сессия сохраняется и разбирается | e2e-тест `frontend/e2e/tests/сбой-сети.spec.ts`, три прогона из трёх |
| запись в БД ≥ 100 операций/с | 1516 правок карточки в секунду, 3234 изменённых строки в секунду; p99 правки 41 мс | 50 параллельных потоков, 20 с |
| аналитический отчёт ≤ 30 с | отчёт по группе — 0,56–0,71 с; отчёт по вызову (JSON, CSV) — 7–11 мс | 5380 карточек и 5330 разборов в базе |
| задержка VoIP ≤ 150 мс | не измерялась (SIP нет) | это не время ответа языковой модели. Телефонного канала (SIP) нет: голос — программная эмуляция, которую заказчик признал достаточной (27.09); реплика распознаётся за 0,2–0,3 с, ответ синтезируется за 0,5–0,7 с (раздел 3.10) |

**Что замер нашёл и что исправлено.** Начало вызова обучало модель прогноза заново на всей истории: p99 доходил до 2,45 с — за нормативом. Теперь история читается одним запросом, модель обучается раз в минуту в фоне, p99 — 0,19 с. Журнал диспетчера считал отметки своей службы для всех карточек до выбора страницы: 135 мс на 8879 карточках и рост с базой; теперь 16 мс. Канал событий после обрыва в 30 с возвращался ещё примерно через 18 с — теперь переподключается сразу, как браузер сообщает о сети.

**Чего замер не показывает.** Текст сводки по группе пишет языковая модель — это время сюда не входит (около минуты, раздел 6.4); числовой отчёт от модели не зависит. Не мерились: модель под нагрузкой, сбой сети при сотне пользователей, настольный процессор. Вопрос заявителю, заданный во время обрыва, не досылается сам: курсант повторяет его, когда сеть вернулась, — правки карточки при этом не теряются.

## 6.4. Ограничения решения

- **Голос — только со старшим бригады.** Диспетчер ДДС говорит со старшим голосом, ответы озвучиваются (раздел 3.10). Разговор с вышестоящим начальником голосом и голос заявителя 112 не сделаны: у оператора 112 вопросы заявителю выбираются из списка, ответы — текстом. Телефонии (SIP) нет — программная эмуляция в браузере.
- **Подбор служб только по типу происшествия.** По ответу заказчика службы в боевой системе подтягиваются ещё и по району обслуживания и подчинённости объекта (школа → ДДС департамента образования, управы, округа). Справочника «адрес → службы», по словам заказчика, нет в природе; территориальных получателей тренажёр не подбирает (`OPEN-QUESTIONS.md`, вопрос 15).
- **Нет сообщения ДДС в 112 об ошибке в карточке.** По ответу заказчика диспетчер узнаёт об ошибке из звонка бригады и сообщает в 112 по телефону. Эталонных примеров ошибок заказчик не дал, поэтому ошибки в карточки ДДС тренажёр не подкладывает.
- **Дообучения модели по правкам преподавателя нет** (раздел 4.6). Вердикты преподавателя по замечаниям модели (раздел 3.9) хранятся и попадают в отчёты, но на следующие ответы модели не влияют.

- **Нейросетевой анализ текста не сверен с экспертами на выборке.** Проверен на отдельных вызовах; вид замечания модель от прогона к прогону путает. Поэтому замечания модели балл не меняют, а решение по ним за преподавателем (раздел 3.9).
- **Какая версия классификатора эталонная** (v046_24 или v046_11), заказчик ещё не ответил. Активна v046_24; администратор может загрузить и активировать другую, разницу между версиями и затронутые учебные вызовы отдаёт API (`/api/classifier/versions/{a}/diff/{b}`, `…/impact`).
- **Сводка по группе считается около минуты** — числа берёт база, но формулирует их модель на процессоре.
- **Кнопки боевого интерфейса без действия.** Экран копирует боевую систему, и эти кнопки оставлены на своих местах, чтобы курсант учился на знакомом экране. Нажатие ничего не делает, подсказка сообщает «в тренажёре не реализовано», для экранного диктора они помечены недоступными. Это: отключение звонка, записи звонков и список SMS, подстановка номера из АОН (полоса звонка); отметки «Нет на месте / отказ от скорой» и «Нет доступа / заблокированные» (карточка 112); «просмотр» и «дополнение» в шапке карточки, отметки ЧС и ЧП (карточка ДДС); расширенный поиск по параметрам (журнал); карта там, где она не подключена к адресу. В оценку эти действия не входят.
- **Тренажёр не подключается к боевой ПОВ-112.** Он воспроизводит её интерфейс и логику по материалам задачи; обмена данными с действующей системой нет и не предполагается.
- **Часть решений принята при неполных исходных данных.** Все такие места перечислены в `OPEN-QUESTIONS.md` с указанием, что именно неизвестно и какое допущение сделано, — а не замаскированы.

---

## 7. Сборка, установка и запуск

Для стенда — раздел 7.7, одна команда. Разделы 7.1–7.6 — локальный запуск для разработки.

### 7.1. Что должно быть на машине

| Компонент | Версия | Проверено на |
|---|---|---|
| Rust | см. примечание | 1.98.1 |
| Node.js | 20.19+ | 20.20.0 |
| PostgreSQL | 14+ | 16 (в контейнере) |
| Docker | любая | для базы; необязателен |

Нижняя граница версии Rust не проверялась: указана та, на которой решение собрано. Редакция языка — 2021.

### 7.2. База данных

```
docker run -d --name arm112-db \
  -e POSTGRES_USER=arm112 -e POSTGRES_PASSWORD=arm112 \
  -e POSTGRES_DB=arm112 -p 5432:5432 postgres:16
```

Схема, учебные учётные записи и выверенные учебные вызовы разворачиваются миграциями при первом запуске сервера.

### 7.3. Сервер приложения

```
cd backend
cp .env.example .env          # при необходимости поправить DATABASE_URL
cargo run --release           # http://localhost:8080, накатит миграции
```

Классификатор ставится отдельной командой (один раз), после чего сервер нужно перезапустить — опросные карты выводятся из классификатора при старте:

```
cargo run --release --bin import_classifier -- \
  ../task/Классификатор_происшествий_v_046_24*.xlsx "v046_24"
```

Описание API после запуска: `http://localhost:8080/api/docs`. Учётные записи: `admin`, `teacher1`, `student1`…`student5` (курсанты разных служб), пароль у всех `arm112`.

### 7.4. Веб-клиент

```
cd frontend
npm run install:all
npm run build                 # сборка в apps/react/dist
npm run dev                   # разработка, http://localhost:5173
```

Собранный клиент — статические файлы, отдаётся любым веб-сервером.

### 7.5. Сервер модели

Подробная процедура, включая наложение патчей MTP и переквантование весов, — `backend/docs/MODEL-SERVER.md`. Кратко:

```
llama-server -m GigaChat3.1-10B-A1.8B-q4_K_M.gguf \
  --host 127.0.0.1 --port 8090 -t 6 -c 8192 \
  --spec-type draft-mtp --spec-draft-n-max 1
```

Сервер приложения подключается к нему переменными окружения:

```
ML_PROVIDER=http
ML_BASE_URL=http://127.0.0.1:8090
```

Без них сервер работает на заглушке: журнал, карточки, классификация, занятия, оценка, разбор ДДС, прогноз и рекомендации полностью функциональны; нет только подготовки и правки учебных вызовов моделью, словесной сводки по группе и нейросетевого анализа текста (он помечается «модель недоступна»).

### 7.5а. Сервер голоса

Необязателен: без него разговор со старшим бригады идёт текстом.

```
python3 -m venv .venv-voice && .venv-voice/bin/pip install -r voice/requirements.txt
# веса: istupakov/gigaam-v3-onnx (файлы v3_e2e_rnnt*) и TeraSpace/TeraTTSv2
# в каталог /путь/к/голосу — см. deploy/README.md, шаг 3а
cd voice && VOICE_MODELS_DIR=/путь/к/голосу VOICE_THREADS=4 \
  ../.venv-voice/bin/uvicorn server:app --host 127.0.0.1 --port 8091
```

Сервер приложения запускать с `VOICE_BASE_URL=http://127.0.0.1:8091`. Замер скорости — `voice/bench.py`.

### 7.5б. Сервер сверки описания

Необязателен: без него описание курсанта сверяет языковая модель.

```
python3 -m venv .venv-nli
.venv-nli/bin/pip install torch --index-url https://download.pytorch.org/whl/cpu
.venv-nli/bin/pip install -r nli/requirements.txt
# чекпоинт: AlexWortega/openjev, подкаталог qwen3.5-2b-nli-v5 — deploy/README.md, шаг
3а'
cd nli && NLI_MODEL_DIR=/путь/к/qwen3.5-2b-nli-v5 NLI_THREADS=6 \
  ../.venv-nli/bin/uvicorn server:app --host 127.0.0.1 --port 8093
```

Сервер приложения запускать с `NLI_BASE_URL=http://127.0.0.1:8093`. Замер скорости — `nli/bench.py`, точности — `backend/docs/замеры/ОПИСАНИЯ.md`.

### 7.6. Проверки

```
cd backend && cargo test            # 323 проверки
cd frontend/e2e && npx playwright install chromium   # один раз
cd frontend && npm test             # 71 сценарий в браузере

# Анализ текста настоящей моделью: нужен поднятый сервер модели
cd backend && cargo test --test text_analysis -- --ignored --nocapture
```

Проверки работают на **отдельной базе** (`TEST_DATABASE_URL` в `backend/.env`), а браузерный прогон поднимает свой сервер и клиент на своих портах — рабочий стенд они не трогают. Подготовка тестовой базы — `CONTRIBUTING.md`.

### 7.7. Развёртывание стенда

Весь тренажёр поднимается на чистой ВМ одной командой через docker compose:

```
deploy/up.sh
```

| Сервис | Что это | Наружу |
|---|---|---|
| `web` | nginx: собранный клиент, прокси `/api` и `/ws` на сервер | один порт (80) |
| `backend` | сервер тренажёра, release-сборка; ежесуточная копия базы | нет |
| `db` | PostgreSQL 16 | нет |
| `model` | llama.cpp с патчем MTP и весами GigaChat | нет |

При первом запуске скрипт создаёт `deploy/.env` со случайными паролем базы и ключом подписи токенов, сервер сам накатывает миграции и импортирует классификатор. Модель включается, только если найден файл весов; без него стенд работает на заглушке (раздел 7.5). Проверка стенда — `deploy/check.sh`, ничего не меняет.

Требования к ВМ: 6 ядер x86-64, 32 ГБ памяти с моделью (16 ГБ без неё), 40 ГБ диска, Ubuntu 22.04 или 24.04, видеокарта не нужна. Подробно — `deploy/README.md`.

---

## 8. Перечень использованных библиотек

Полные версии зафиксированы в `backend/Cargo.lock` и `frontend/apps/react/package-lock.json`.

### 8.1. Сервер — прямые зависимости

| Библиотека | Версия | Лицензия | Назначение |
|---|---|---|---|
| tokio | 1.53.1 | MIT | асинхронная среда выполнения |
| axum | 0.8.9 | MIT | HTTP-сервер и маршрутизация |
| tower, tower-http | 0.5.3, 0.6.11 | MIT | промежуточные слои, статика, CORS |
| sqlx | 0.8.6 | MIT / Apache-2.0 | доступ к PostgreSQL, миграции |
| serde, serde_json | 1.0.229, 1.0.151 | MIT / Apache-2.0 | сериализация |
| argon2, password-hash | 0.6.0, 0.6.1 | MIT / Apache-2.0 | хранение паролей |
| jsonwebtoken | 11.1.0 | MIT | токены доступа |
| reqwest | 0.12.28 | MIT / Apache-2.0 | обращение к серверу модели |
| tokio-tungstenite | 0.29.0 | MIT | канал событий WebSocket |
| utoipa, utoipa-swagger-ui | 5.5.0, 9.0.2 | MIT / Apache-2.0 | схема OpenAPI |
| calamine | 0.36.1 | MIT | чтение файлов классификатора |
| chrono | 0.4.45 | MIT / Apache-2.0 | время и нормативы |

| Библиотека | Версия | Лицензия | Назначение |
|---|---|---|---|
| uuid | 1.26.1 | Apache-2.0 / MIT | идентификаторы |
| tracing, tracing-subscriber | 0.1.44, 0.3.23 | MIT | журналирование |
| anyhow, thiserror | 1.0.104, 2.0.20 | MIT / Apache-2.0 | обработка ошибок |
| rand | 0.10.3 | MIT / Apache-2.0 | генерация значений |
| async-trait | 0.1.92 | MIT / Apache-2.0 | трейты адаптеров моделей |
| dotenvy | 0.15.7 | MIT | чтение настроек |
| futures-util, http-body-util | 0.3.34, 0.1.5 | MIT | вспомогательные |

Полный граф — **344 пакета**. Распределение лицензий: MIT и/или Apache-2.0 — 280, Unicode-3.0 — 18, остальные (BSD, ISC, Zlib, Unlicense, CDLA-Permissive) — 46. **Копилефт-лицензий, обязывающих раскрывать исходный код, в графе нет.**

### 8.2. Клиент — прямые зависимости

| Библиотека | Версия | Лицензия | Назначение |
|---|---|---|---|
| react, react-dom | 19.3.0 | MIT | интерфейс |
| react-router-dom | 7.18.4 | MIT | маршрутизация |
| zustand | 5.0.15 | MIT | состояние |
| vite, @vitejs/plugin-react | 8.3.0, 6.1.1 | MIT | сборка |
| sass | 1.104.1 | MIT | стили |
| typescript | 6.0.3 | Apache-2.0 | типизация |
| oxlint | 1.83.0 | MIT | статический анализ |
| @types/* | — | MIT | описания типов |

Диаграммы аналитики нарисованы средствами SVG — сторонней библиотеки для графиков в поставке нет.

В дереве сборки присутствует `lightningcss` 1.33.0 под **MPL-2.0** (преобразователь CSS внутри Vite). Это инструмент сборки: в поставляемый клиент его код не попадает, изменения в него не вносились, поэтому требования MPL о раскрытии изменённых файлов не возникают.

### 8.3. Проверки (в поставку не входят)

Playwright (Apache-2.0) — сценарии в браузере.

### 8.4. Модель и развёртывание

| Компонент | Лицензия |
|---|---|
| GigaChat 3.1 10B-A1.8B | MIT |
| llama.cpp | MIT |

| Компонент | Лицензия |
|---|---|
| GigaAM v3 (распознавание речи, ONNX `istupakov/gigaam-v3-onnx`) | MIT |
| onnx-asr, onnxruntime | MIT |
| TeraTTSv2 (синтез речи) | в карточке модели не указана; модуль ударений (RUAccent) — MIT |
| FastAPI, uvicorn (серверы голоса и сверки) | MIT, BSD-3-Clause |
| OpenJEV (кросс-энкодер сверки описания, `AlexWortega/openjev`) | MIT (в карточке модели) |
| PyTorch, transformers (сервер сверки) | BSD-3-Clause, Apache 2.0 |
| PostgreSQL | PostgreSQL License |
| nginx | BSD-2-Clause |

Лицензия MIT у весов модели существенна: она разрешает коммерческое использование, в отличие от распространённых среди русскоязычных моделей лицензий с оговоркой NonCommercial, неприменимых для государственного заказчика.

Два патча к llama.cpp (`backend/docs/mtp-1-converter.patch`, `mtp-2-runtime.patch`) написаны в рамках этой работы и распространяются на условиях лицензии llama.cpp.

---

## 9. Состав документации репозитория

| Файл | О чём |
|---|---|
| `README.md` | обзор, быстрый старт |
| `deploy/README.md` | развёртывание стенда на ВМ, эксплуатация |
| `BACKEND.md` | схема базы, контракт API, домен |
| `INTEGRATION.md` | встраивание в стороннюю систему |
| `PROVENANCE.md` | происхождение каждого набора данных и наши допущения |
| `OPEN-QUESTIONS.md` | вопросы к заказчику и принятые допущения |
| `CHAT-FINDINGS.md` | что уточнено в чате задачи и как это отражено в решении |
| `CONTRIBUTING.md` | правила работы с кодом, тестовая база |
| `backend/docs/MODEL-SERVER.md` | сборка и запуск сервера модели, замеры |
| `frontend/README.md` | архитектура клиента |
| `frontend/SCENARIOS.md` | сопоставление с экранами боевой системы |
| `frontend/DEFECTS.md` | найденные проверками дефекты |