Тренажёр оператора ДДС города Москвы

Сопроводительная документация

Задача №9 Департамента по делам гражданской обороны, чрезвычайным ситуациям и пожарной безопасности города Москвы. Лидеры цифровой трансформации, 2026.

---

1. Назначение

Тренажёр готовит операторов дежурно-диспетчерских служб и Системы-112 к работе в боевой системе **ПОВ-112 (АРМ-112)**. Оба участка из ТЗ отрабатываются в интерфейсе, повторяющем боевой:

- **оператор 112** принимает учебный вызов: выясняет у заявителя обстоятельства, заполняет карточку происшествия, классифицирует его и оповещает службы;
- **диспетчер ДДС** получает поток карточек своей службы: принимает или мотивированно отклоняет, назначает бригаду, по докладам старшего ведёт статусы реагирования до завершения.

Преподаватель проводит занятия по группе, готовит учебные вызовы и видит аналитику. После каждого вызова курсант получает разбор с ценой каждой ошибки, прогноз своего результата и рекомендации — и то, и другое система потом проверяет фактом. Свободный текст курсанта читает модель и указывает расхождения с услышанным, с цитатами; преподаватель подтверждает их и ставит экспертную оценку рядом с автоматической.

Ключевая особенность решения — **тренажёр отличает выясненное от угаданного**. Раздел 3.3 объясняет, почему это главная метрика подготовки оператора.

---

2. Состав решения

Компонент	Технология	Назначение
Веб-клиент	React 19, TypeScript, Vite	интерфейс АРМ-112 и учебный слой
Сервер приложения	Rust, axum, tokio	API, домен, оценка, фоновые задачи
Хранилище	PostgreSQL 16	классификатор, вызовы, занятия, журналы, настройки
Языковая модель	GigaChat 3.1 10B-A1.8B на llama.cpp	подготовка учебных вызовов, правка по переписке, сводки, анализ текста курсанта

Все четыре компонента разворачиваются на одной машине без выхода в интернет и без графического ускорителя — одной командой, раздел 7.7. Обоснование выбора — раздел 6.

Объём исходного кода: 15 848 строк Rust в 63 файлах, 5 673 строки TypeScript в 49 файлах, 28 миграций схемы базы.

---

3. Методы обработки данных

3.1. Классификация происшествия — детерминированная, без нейросети

Единый классификатор происшествий (ЕКП) — это таблица, где каждой комбинации признаков соответствует **ровно один** правильный ответ. Поэтому классификацию считает не модель, а прямой поиск по таблице:

```
ответы карты ──①──▶ признаки ──②──▶ позиция ЕКП ──③──▶ список оповещения
```

① Ответы опросной карты сопоставляются с признаками трёх уровней («где», «что именно», «уточнение»). ② По группе и признакам ищется позиция классификатора. Если незаполненный уровень признаков оставляет несколько позиций с разными исходами, система **не выбирает первую попавшуюся**, а называет варианты и просит уточнить — так же ведёт себя боевая система. ③ Позиция задаёт список оповещения. Службы, получающие лишь копию карточки (значения «карточка-112», «нет реагирования»), отделяются от реагирующих: оценка не должна штрафовать за то, что оператор их не вызвал.

В активной версии классификатора **1 283 позиции в 24 группах**, **134 593 строки матрицы оповещения**, 60 служб.

Такой выбор даёт воспроизводимость: эталон для учебного вызова не зависит от того, какая модель загружена и загружена ли вообще.

3.2. Опросные карты для всех типов происшествия

В выпадающем списке «Что случилось?» — **51 тип**, как в боевой системе (полный список передан экспертами в чате задачи). Опросная карта есть у **44** из них:

- **3 карты сняты с кадров боевой системы** (101 — пожар, 104 — газ, «Взрыв»): формулировки вопросов и вариантов дословные. Карта 101 снята по трём веткам — «Дом», «Улица» и «Транспорт»;
- **41 карта выведена из классификатора**: опросная карта боевой системы — это дерево признаков группы, и классификатор содержит его целиком. Подписи вопросов — заголовки столбцов классификатора, варианты — дословно из ячеек. Ничего не сочинено;
- **у 7 типов карты нет** («Внутренний звонок», «Нецелевой вызов», «Технический сбой» и др.): это виды обращений, а не происшествия, в классификаторе им не соответствует ни один признак. Интерфейс так и пишет, а не показывает пустую форму.

Карта **растёт по мере ответов**, как на кадрах боевой системы:

- варианты второго признака зависят от первого (`depends_on`): у «ДТП» одни, у «ДТП с пострадавшими» — другие; смена первого признака снимает неподходящие ответы на втором;
- вопрос целиком появляется только при нужном ответе (`show_when`): на пустом «Где» у пожара видны только «Где» и «Описание», после «Улица» — «Признак пожара», «Доступ», «Место происшествия», а «Описание правонарушения» — лишь после «Есть правонарушение».

Карты выводятся при каждом запуске сервера и при активации новой версии классификатора — поэтому смена версии не оставляет устаревших карт.

3.3. Оценка оператора 112 — три слоя

Разбор сравнивает три независимых слоя данных:

Слой	Что это
Скрытая истина	что на самом деле произошло, заложено в сценарий
Стенограмма	что заявитель действительно сообщил в разговоре
Карточка	что оператор ввёл в поля

Из сопоставления рождаются четыре вида замечаний с разным весом:

Вид	Вес	Смысл
`guessed`	1	значение верное, но заявитель его не сообщал — **угадал**
`extra`	1	вызвана лишняя служба
`missing`	2	служба не оповещена
`wrong`	3	значение не совпало с эталоном

Превышение норматива времени добавляет 2.

Замечание формулируется как последствие, а не как балл: не «−3 за поле „служба“», а «служба не оповещена — фактически не выехала».

Смысл метрики «угадал»: оператор, угадавший тип происшествия по первой фразе, в боевой обстановке ошибётся, как только вызов окажется нетипичным. На данных стенда доля угаданного составила **38 %** — то есть больше трети верных ответов курсанты не выясняли у заявителя.

3.4. Работа диспетчера ДДС: статусы, нормативы, бригада

Статусы реагирования идут строго по памятке ДДС: сначала «Принята» или «Не принята», затем «Начало реагирования» → «Прибытие» → «Проведение работ» → «Работы завершены» или «Отказ от выполнения работ». Порядок проверяется на сервере, а не только в интерфейсе. «Не принята» и «Отказ» без комментария сервер не принимает: заказчик требует мотивированного отказа. Поля, которые заполнил оператор 112, диспетчер ДДС не редактирует — только свои статусы и комментарии к ним.

Нормативы — по ответу заказчика в чате задачи (27.09.2026):

Норматив	Значение	Отсчёт
Открыть карточку	30 с	с момента появления карточки в строке сообщений
Первая запись: статус и текст	3 мин	см. ниже

Открытие карточки фиксируется системной отметкой «Получена службой». Точка отсчёта трёх минут в ответе заказчика («3 минуты на открытие карточки и добавление первой записи») однозначно не закреплена; мы считаем от поступления карточки. Остальные временные показатели заказчик не определял: работы могут идти часами и днями.

Статус карточки не хранится как состояние конечного автомата, а **выводится** из состояния служб и прошедшего времени. Фоновая задача (тик 5 секунд) пересчитывает статусы и переводит карточки в «Не оповещено» (норматив открытия или первой записи истёк) и «Не завершено» (48 часов, памятка ДДС). Запись условная — по прежнему статусу, поэтому два экземпляра сервера не запишут переход дважды.

Бригада. По ответам заказчика бригаду диспетчер выбирает вручную, а сведения о ходе работ получает от старшего: тот звонит с докладом сам, или диспетчер сам звонит ему. В тренажёре живут оба варианта:

- этапы работ бригады наступают по шкале от момента назначения — это скрытая истина, как факты заявителя у оператора 112;
- старший докладывает о наступившем этапе с задержкой; диспетчер, который позвонил раньше, узнаёт раньше. Доклад называет только этап («прибыли на место») — обстановку на месте мы не придумываем.

Разбор диспетчера ДДС проверяет требование памятки «статусы по факту получения информации»:

Замечание	Вес	Смысл
статус раньше доклада	2	«не по факту» — аналог «угадал» у оператора 112
доклад без статуса	2	служба 112 и соседние ДДС не видят хода работ
принята, бригада не назначена	2	на место никто не выехал
статус позже доклада сверх норматива	1	в карточке устаревшая картина
карточка открыта позже 30 с	1	норматив заказчика
первая запись позже 3 мин или без текста	1	норматив заказчика

Что здесь — наше допущение, а не норматив заказчика. Число учебных бригад (3), шкала этапов (выезд 20 с, путь 40 с, начало работ 20 с, работы 60 с), задержка доклада (25 с) и норматив обновления статуса после доклада (30 с) заказчик не называл. Шкала сжата под учебное занятие, одна на все службы — заказчик сам попросил «универсальный алгоритм для всех». Всё вынесено в настройки и перечислено в `PROVENANCE.md` («Наши допущения») и `OPEN-QUESTIONS.md` (вопрос 18).

3.5. Прогноз результата и его проверка

Критерий экспертизы просит не прогноз, а **его проверку** — сравнение прогнозных значений с реальными. Поэтому устройство такое:

1. **Прогноз фиксируется до начала вызова** и задним числом не переписывается; факт проставляется после разбора. Точность показывается только по фактически сделанным прогнозам.
2. **Модель — гребневая регрессия**, а не нейросеть: данных мало, сложная модель переобучится, а на разборе нужно показать, из чего сложился прогноз. Признаки — по последним разборам курсанта: средний балл, тренд, доля угаданного, доля превышений норматива, опыт, средний балл на той же группе классификатора. Коэффициенты считаются решением нормальных уравнений, без внешних библиотек.
3. **Рядом всегда базовая линия** — средний балл курсанта. Пока пар «прогноз — факт» меньше 30, модель не обучается и прогноз делает базовая линия; при истории меньше 3 разборов прогноз помечается недостоверным.
4. Достоверность — средняя абсолютная ошибка, доля попаданий в допуск (по умолчанию ±10 баллов) и та же ошибка у базовой линии: видно, стоит ли модель своих сложностей.

Курсант видит свой прогноз с разложением по признакам в разборе, преподаватель — достоверность прогноза по группе в аналитике.

3.6. Рекомендации курсанту и проверка их исполнения

Рекомендация сама по себе — декларация, поэтому проверяется так же, как прогноз. После разбора система ищет **повторяющиеся** ошибки: одно и то же поле с тем же видом замечания в последних разборах. Текст рекомендации собирается только из замечаний разбора — подпись поля плюс заготовка по виду ошибки, — модель его не пишет.

Рекомендация фиксируется с временем. В первом следующем разборе, где ошибка могла повториться, ставится вердикт: ушла или нет. Доля сработавших — измеренная величина, и рядом базовая линия: как часто та же повторяющаяся ошибка уходит сама, без рекомендации.

Пороги — **наше допущение** (`OPEN-QUESTIONS.md`, вопрос 19): окно 5 разборов, повтор не меньше 2 раз, открытых рекомендаций не больше 3, о доле судим не раньше 5 проверок. Сравнение с базовой линией строже к рекомендациям, чем к ней самой: рекомендации достаются самым частым ошибкам. На экране это сказано.

3.7. Языковая модель — только текст

Модель отвечает за то, что нельзя посчитать: черновики учебных вызовов (первая фраза заявителя, его ответы на вопросы), правку вызова по переписке с преподавателем, словесные сводки по группе. **Эталон для оценки она не считает никогда** — его считает классификатор. Пока курсант ведёт вызов, модель не вызывается: ответы заявителя подготовлены заранее и выверены преподавателем. С попыткой курсанта модель связана одним: после сохранения она в фоновой очереди читает его свободный текст (раздел 3.9). Разбор правил курсант видит сразу, анализ модели приходит следом.

При подготовке учебного вызова конвейер устроен так:

1. признаки выбираются из **закрытого словаря** опросной карты;
2. ответы, которых нет в словаре, отбрасываются;
3. классификатор считает эталон;
4. если он жалуется (например, «уточните признак второго уровня»), его жалоба возвращается модели как замечание, и шаг повторяется;
5. только после этого модель пишет текст легенды и скрытых фактов.

Ответ модели ограничен **схемой JSON на уровне декодирования** (`response_format: json_schema`): движок отбрасывает токены, нарушающие схему, поэтому структурно неверный ответ невозможен.

Где работает модель. Сервер приложения обращается к ней по протоколу, совместимому с OpenAI API; адрес задаётся переменной `ML_BASE_URL`. В поставке это локальный llama.cpp на той же машине — внешних обращений нет, данные никуда не уходят. Тот же адрес можно направить на другой совместимый сервер (vLLM, Ollama) во внутреннем контуре, не меняя кода. При развёртывании через `deploy/up.sh` достаточно указать `ML_BASE_URL` в `deploy/.env` — тогда свой контейнер модели не поднимается.

3.8. Исходные данные

Все данные, на которых работает тренажёр, взяты из материалов задачи и ответов экспертов. Их происхождение построчно зафиксировано в `PROVENANCE.md`:

- **ЕКП** — файлы классификатора двух версий (v046_11 от 15.11.2024 и v046_24 с корректировкой МВД и Департамента), импортированы целиком;
- **учебные вызовы** — 96 обращений, разобранных из 32 бумажных билетов; у всех 96 разобран телефон, у 57 — ФИО заявителя, у 25 — скрытый адрес. Из них готовятся учебные вызовы (раздел 4.5);
- **интерфейс** — снят по скриншотам боевой системы, сопоставление кадров описано в `frontend/SCENARIOS.md`; полный список типов происшествия, ветки карты 101 и справочник служб — по материалам, переданным экспертами в чате задачи.

Где данных заказчика не хватило, параметр вынесен в настройки и помечен как наше допущение (`PROVENANCE.md`, «Наши допущения»). Синтетических данных, выданных за данные заказчика, в поставке нет.

3.9. Нейросетевой анализ ручного ввода и экспертная оценка

ТЗ требует оценки «в том числе на основе анализа ручного ввода текста», «на основе нейросетевого анализа» и просмотра результатов как «автоматическая оценка И экспертная оценка». Всё, что проверяется сравнением, — признаки, адрес, службы, статусы, время — проверяют правила (разделы 3.3, 3.4). Правила не умеют читать свободный текст; это делает модель.

Что читает модель.

Попытка	Текст курсанта	С чем сверяется
Оператор 112	«Описание со слов заявителя», описательный адрес	реплики заявителя из стенограммы вызова
Диспетчер ДДС	комментарии к статусам реагирования	описание из карточки 112 и полученные доклады бригады

Анализ ставится в очередь при сохранении карточки 112 и при закрывающем статусе ДДС («Работы завершены», «Отказ от выполнения работ», «Не принята»).

Как устроен запрос. Модель не ищет расхождения сама — модель такого размера их пропускает: на пробном вызове она не заметила «горит баня» вместо «горит крыша дома». Вместо этого она разбирает текст курсанта по утверждениям и про каждое отвечает: подтверждается, противоречит или заявитель этого не сообщал; отдельно — что существенное заявитель сказал, а в тексте нет. Вид замечания из вердикта выводит код. Ответ ограничен схемой JSON на уровне декодирования.

Каждое замечание подтверждено цитатой, и цитата проверяется кодом. Фрагмент текста курсанта ищется в его тексте, фрагмент услышанного — в стенограмме или докладах (без учёта регистра, «ё» и знаков препинания). Не нашлась цитата — замечание отбрасывается, и число отброшенных показывается преподавателю. Так модель не может приписать курсанту слова, которых он не писал, или заявителю — которых тот не говорил.

Балл модель не меняет. Замечания стоят в разборе отдельным блоком «Анализ текста (нейросеть)» со статусом (готовится, готов, модель недоступна), рядом с баллом правил. Преподаватель подтверждает или отклоняет каждое замечание. Модели нет (`ML_PROVIDER=mock`) — анализ честно помечается «модель недоступна», а не выдаёт пустой список, похожий на «замечаний нет». Подняли модель — преподаватель повторяет анализ кнопкой, курсанту проходить вызов заново не нужно.

Экспертная оценка. В карточке, открытой из журнала, преподаватель видит все попытки по ней — вызов 112 и работу каждой службы ДДС — и ставит экспертный балл 0–100 с комментарием. Автоматический балл при этом не переписывается: оба хранятся и показываются рядом, курсант видит оба и комментарий. Каждая оценка и её изменение пишутся в журнал действий (`grade.override`) вместе с автоматическим и прежним баллом, вердикты по замечаниям модели — тоже (`analysis.verdict`). Экспертный балл есть в отчёте по занятию (JSON и CSV) и в отчёте по группе. Администратор экспертную оценку не ставит: ТЗ запрещает ему вмешиваться в оценки, и мы не даём ему этого вовсе.

Проверено. Код вокруг модели — очередь, проверка цитат, хранение, права, аудит — покрыт проверками с подставной моделью. На настоящей модели (GigaChat 3.1 10B-A1.8B, llama.cpp, 6 потоков) проверено на нарочно испорченном описании вызова «горит крыша частного дома»: «Горит баня на участке, есть пострадавший. Дом газифицирован.» Модель нашла все четыре расхождения — баню вместо крыши дома, пострадавшего при «пострадавших нет», газификацию, о которой заявитель не говорил, и незаписанное «пламя видно». Ответ занимает **26–33 секунды** на процессоре. **Чего не проверяли:** согласие модели с экспертами на выборке вызовов — такой выборки у нас нет. Вид замечания («не записано» или «противоречие») модель от прогона к прогону путает, суть — нет; поэтому решение по каждому замечанию за преподавателем.

---

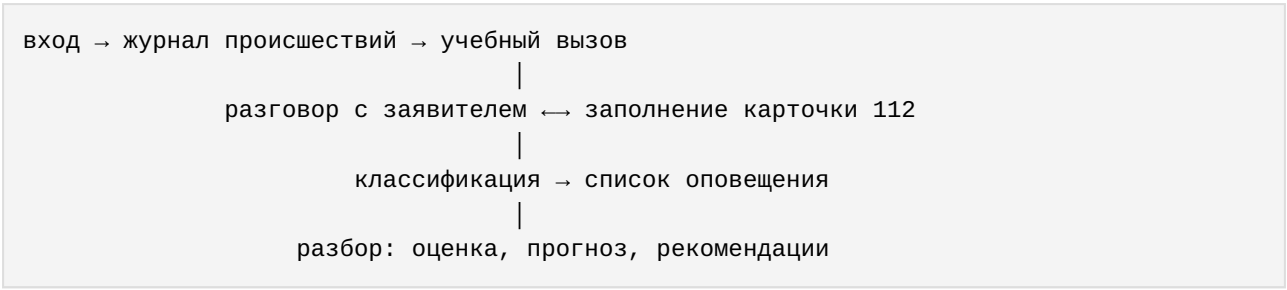
4. Функциональная архитектура

4.1. Роли

Роль	Доступ
Курсант	учебные вызовы, карточки своей службы, своя история, разбор, прогноз, рекомендации, свои автоматическая и экспертная оценки
Преподаватель	занятия, подготовка вызовов, группы, аналитика по группе, экспертная оценка попыток и вердикты по замечаниям модели
Администратор	версии классификатора, учётные записи, настройки, системные журналы; оценки видит, но не ставит

Разграничение проверяется на сервере при каждом запросе; интерфейс скрывает недоступные разделы, но не является средством защиты.

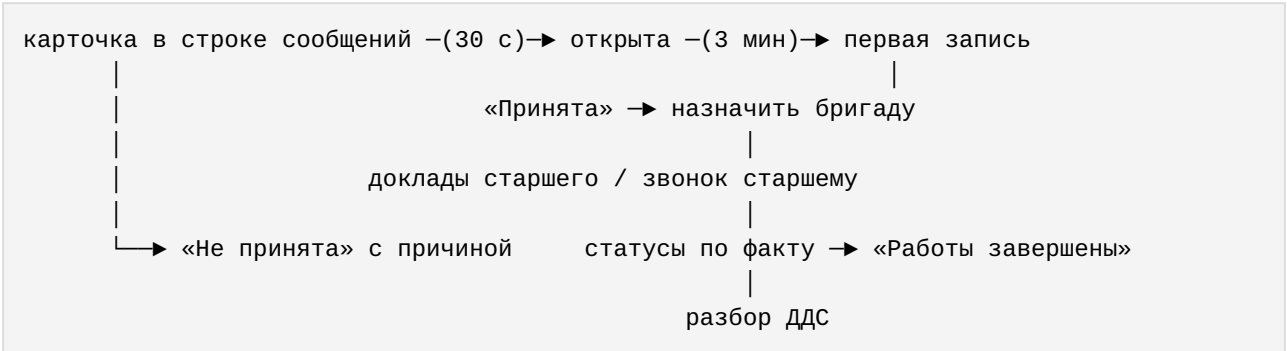
4.2. Оператор 112



Курсант задаёт заявителю вопросы; ответ помечает факт выясненным — на этом держится разбор «узнал или угадал». Ввод в карточку уходит на сервер пакетами; правки в пределах одного окна **сливаются вглубь**, а не затирают друг друга. При обрыве сети пакет повторяется.

4.3. Диспетчер ДДС

Сохранённая оператором 112 карточка приходит в журнал каждой службы из списка оповещения. Диспетчер работает с несколькими карточками одновременно, как в текущей работе: пока он занят одной, время идёт и у ожидающих.



Звонок старшему и входящие доклады приходят в карточку ДДС текстом.

4.4. Занятие преподавателя

Порядок — из ТЗ (§10, «Проведение практического занятия»): преподаватель создаёт занятие для группы, выбирает режим и категории происшествий под тему, запускает, следит за ходом и завершает в любой момент.

Режим	Что получает группа
Приём вызова (112)	учебные вызовы по выбранным категориям; пока идёт занятие, курсант видит только их
Работа ДДС	карточки по службам курсантов — созданные системой, заполненные курсантами на занятиях 112 или вперемешку; до 5 карточек на службу, в случайном порядке

В режиме ДДС карточки занятия **поступают потоком**: с интервалом, который задаёт преподаватель при создании занятия, — а не все сразу. Ход занятия виден по каждому курсанту: сколько взято, сколько доведено до разбора, средний балл. При завершении недоработанные вызовы закрываются.

4.5. Подготовка учебных вызовов

Преподаватель запускает подготовку вызовов из билетов (конвейер раздела 3.7) и доводит каждый перепиской с моделью: «поменяй ФИО», «добавь, что из мусоропровода идёт пламя», «сделай первую фразу короче». Модель отвечает репликой и правкой; правка применяется к вызову, эталон пересчитывается классификатором. В переписке показывается, что **фактически** изменилось, — по сравнению вызова до и после, а не со слов модели. Сыгранные факты не удаляются, а снимаются с учёта, чтобы не ломать уже пройденные разборы.

Готовый вызов преподаватель утверждает — до утверждения курсанты его не видят. **Преподаватель — конечный валидатор**, как и просит заказчик.

Как правки преподавателя влияют на модель — ровно так: переписка по вызову сохраняется, и последние ходы подаются модели в контекст при следующей правке того же вызова, поэтому «нет, короче» имеет смысл. Весов модели правки не меняют, и на подготовку других вызовов не переносятся. Дообучения модели на правках преподавателя в поставке нет — как это должно выглядеть, заказчик пока не определил.

4.6. Аналитика

Диаграммы (тепловая карта ошибок, динамика, воронка, виды замечаний) строятся из статистики занятий средствами SVG, без сторонних библиотек. Там же — достоверность прогноза и доля сработавших рекомендаций по группе, рядом с базовыми линиями. Словесную сводку по группе формулирует модель — но **числа в неё подаются уже посчитанными**, в виде именованных агрегатов.

4.7. Настраиваемые параметры

Нормативы, параметры прогноза, рекомендаций и шкалы бригады хранятся в таблице настроек, а не в коде. Администратор меняет их через API (`PATCH /api/settings/{key}`); у каждого параметра есть допустимые пределы, значение вне их сервер отклоняет.

---

5. Компонентная архитектура

5.1. Сервер

```
api/        HTTP-обработчики, схема OpenAPI
domain/     классификатор, статусы, оценка, бригада, прогноз, рекомендации
ingest/     импорт классификатора и билетов, вывод опросных карт
reports/    отчёты, прогноз и рекомендации над данными базы
jobs/       фоновые задачи: сторож нормативов, доклады бригад, очередь модели
ml/         адаптеры моделей: HTTP-сервер модели и заглушка
```

Доменный слой не знает ни о HTTP, ни о моделях: классификатор, оценка, разбор ДДС, прогноз и рекомендации — чистые функции над данными. Поэтому все **278 серверных проверок** выполняются без поднятия модели; там, где важен ответ модели, её заменяет подставная.

Описание API машиночитаемо (OpenAPI, utoipa). Отдельная проверка читает список маршрутов из исходного кода и **падает при расхождении** со схемой.

5.2. Клиент

Слоистая раскладка (Feature-Sliced Design): `shared` → `entities` → `widgets` → `pages`. Состояние — zustand, стили — модули SCSS, маршрутизация — HashRouter (стенд отдаётся статикой без настройки переписывания путей).

Канал событий WebSocket с переподключением по возрастающей задержке. Канал — **ускорение, а не источник истины**: при его отказе интерфейс продолжает работать на обычных запросах.

5.3. Сервер модели

llama.cpp в режиме сервера, совместимого с OpenAI API. Подробности — `backend/docs/MODEL-SERVER.md`.

---

6. Условия и ограничения

6.1. Целевой стенд

Процессор Intel Core i7 или Xeon, не менее 6 ядер; 32 ГБ оперативной памяти; **графический ускоритель не предусмотрен**. Это задано системными требованиями, и из этого следует весь выбор в разделе 3.

6.2. Что из этого следует

Модель на процессоре — узкое место. Выбрана **GigaChat 3.1 10B-A1.8B**: из десяти миллиардов параметров на каждом токене работают 1,8 миллиарда (архитектура со смесью экспертов, 64 эксперта, используются 4). Скорость на процессоре определяется активными параметрами, а не общим размером, поэтому модель отвечает как небольшая, а знает как крупная. Лицензия MIT.

Дополнительно включено **спекулятивное декодирование на блоке MTP** (multi-token prediction), встроенном в модель. Поддержки этого режима для данной архитектуры в llama.cpp не было — она добавлена двумя патчами, которые приложены к поставке (`backend/docs/mtp-*.patch`).

Измеренный результат на 6 потоках: **10,3 → 14,8 токенов в секунду, прирост 44 %**. Существенно, что `--spec-draft-n-max 1`: при значении по умолчанию 3 проверка отбрасывала большую часть черновика (доля принятых токенов 30 %), при 1 — принимается 73 %.

Оговорки к замеру. Мерили на AMD EPYC 7532 с **восемью каналами памяти**; ограничены были потоки (6), но не каналы. Генерация на процессоре упирается в пропускную способность памяти, а не в ядра, поэтому это **потолок, а не пол**: на настольном i7 с двухканальной памятью скорость будет ниже. На такой машине мы не мерили и цифру не называем (`OPEN-QUESTIONS.md`, вопрос 11). Сравнивались два прогона при одинаковой нагрузке, а не серия: порядок величины достоверен, вторая значащая цифра — нет.

Скорость модели не влияет на нормативы ТЗ: пока курсант ведёт вызов, модель не вызывается (раздел 3.7), а подготовка вызовов, сводки и анализ текста после сохранения идут в фоновой очереди. Очередь одна: если группа из двадцати курсантов сохранит карточки разом, анализ последнего придёт через двадцать ответов модели. Разбор правил от этого не зависит — он приходит сразу.

6.3. Требования ТЗ к производительности — что к чему относится

Требование ТЗ (§7)	К чему относится	У нас
отклик интерфейса ≤ 2 с при 100 пользователях	запросы к серверу приложения	модель в этот путь не входит; подбор служб по признакам — прямой поиск по таблице
задержка VoIP ≤ 150 мс	передача голоса	это не время ответа языковой модели; голосового канала в текущей поставке нет (раздел 6.4)
отчёт ≤ 30 с	аналитические отчёты	считаются в фоновой очереди из базы
сбой сети до 30 с	восстановление сессии	пакеты ввода повторяются, канал событий переподключается

6.4. Ограничения решения

- **Голос.** В текущей поставке разговор ведётся текстом: курсант выбирает вопросы заявителю, доклады старшего бригады приходят текстом. Точки подключения распознавания и синтеза речи заложены (`ml/`); голосовой канал — отдельная работа, в поставку на момент написания не вошёл.
- **Подбор служб только по типу происшествия.** По ответу заказчика службы в боевой системе подтягиваются ещё и по району обслуживания и подчинённости объекта (школа → ДДС департамента образования, управы, округа). Справочника «адрес → службы», по словам заказчика, нет в природе; территориальных получателей тренажёр не подбирает (`OPEN-QUESTIONS.md`, вопрос 15).
- **Нет сообщения ДДС в 112 об ошибке в карточке.** По ответу заказчика диспетчер узнаёт об ошибке из звонка бригады и сообщает в 112 по телефону. Эталонных примеров ошибок заказчик не дал, поэтому ошибки в карточки ДДС тренажёр не подкладывает.
- **Дообучения модели по правкам преподавателя нет** (раздел 4.5). Вердикты преподавателя по замечаниям модели (раздел 3.9) хранятся и попадают в отчёты, но на следующие ответы модели не влияют.
- **Нейросетевой анализ текста не сверен с экспертами на выборке.** Проверен на отдельных вызовах; вид замечания модель от прогона к прогону путает. Поэтому замечания модели балл не меняют, а решение по ним за преподавателем (раздел 3.9).
- **Какая версия классификатора эталонная** (v046_24 или v046_11), заказчик ещё не ответил. Активна v046_24; администратор может загрузить и активировать другую, разницу между версиями и затронутые учебные вызовы отдаёт API (`/api/classifier/versions/{a}/diff/{b}`, `…/impact`).
- **Сводка по группе считается около минуты** — числа берёт база, но формулирует их модель на процессоре.
- **Кнопки боевого интерфейса без действия.** Экран копирует боевую систему, и эти кнопки оставлены на своих местах, чтобы курсант учился на знакомом экране. Нажатие ничего не делает, подсказка сообщает «в тренажёре не реализовано», для экранного диктора они помечены недоступными. Это: отключение звонка, записи звонков и список SMS, подстановка номера из АОН (полоса звонка); отметки «Нет на месте / отказ от скорой» и «Нет доступа / заблокированные» (карточка 112); «просмотр» и «дополнение» в шапке карточки, отметки ЧС и ЧП (карточка ДДС); расширенный поиск по параметрам (журнал); карта там, где она не подключена к адресу. В оценку эти действия не входят.
- **Тренажёр не подключается к боевой ПОВ-112.** Он воспроизводит её интерфейс и логику по материалам задачи; обмена данными с действующей системой нет и не предполагается.
- **Часть решений принята при неполных исходных данных.** Все такие места перечислены в `OPEN-QUESTIONS.md` с указанием, что именно неизвестно и какое допущение сделано, — а не замаскированы.

---

7. Сборка, установка и запуск

Для стенда — раздел 7.7, одна команда. Разделы 7.1–7.6 — локальный запуск для разработки.

7.1. Что должно быть на машине

Компонент	Версия	Проверено на
Rust	см. примечание	1.98.1
Node.js	20.19+	20.20.0
PostgreSQL	14+	16 (в контейнере)
Docker	любая	для базы; необязателен

Нижняя граница версии Rust не проверялась: указана та, на которой решение собрано. Редакция языка — 2021.

7.2. База данных

```
docker run -d --name arm112-db \
  -e POSTGRES_USER=arm112 -e POSTGRES_PASSWORD=arm112 \
  -e POSTGRES_DB=arm112 -p 5432:5432 postgres:16
```

Схема, учебные учётные записи и выверенные учебные вызовы разворачиваются миграциями при первом запуске сервера.

7.3. Сервер приложения

```
cd backend
cp .env.example .env          # при необходимости поправить DATABASE_URL
cargo run --release           # http://localhost:8080, накатит миграции
```

Классификатор ставится отдельной командой (один раз), после чего сервер нужно перезапустить — опросные карты выводятся из классификатора при старте:

```
cargo run --release --bin import_classifier -- \
  ../task/Классификатор_происшествий_v_046_24*.xlsx "v046_24"
```

Описание API после запуска: `http://localhost:8080/api/docs`. Учётные записи: `admin`, `teacher1`, `student1`…`student5` (курсанты разных служб), пароль у всех `arm112`.

7.4. Веб-клиент

```
cd frontend
npm run install:all
npm run build                 # сборка в apps/react/dist
npm run dev                   # разработка, http://localhost:5173
```

Собранный клиент — статические файлы, отдаётся любым веб-сервером.

7.5. Сервер модели

Подробная процедура, включая наложение патчей MTP и переквантование весов, — `backend/docs/MODEL-SERVER.md`. Кратко:

```
llama-server -m GigaChat3.1-10B-A1.8B-q4_K_M.gguf \
  --host 127.0.0.1 --port 8090 -t 6 -c 8192 \
  --spec-type draft-mtp --spec-draft-n-max 1
```

Сервер приложения подключается к нему переменными окружения:

```
ML_PROVIDER=http
ML_BASE_URL=http://127.0.0.1:8090
```

Без них сервер работает на заглушке: журнал, карточки, классификация, занятия, оценка, разбор ДДС, прогноз и рекомендации полностью функциональны; нет только подготовки и правки учебных вызовов моделью, словесной сводки по группе и нейросетевого анализа текста (он помечается «модель недоступна»).

7.6. Проверки

```
cd backend && cargo test            # 278 проверок
cd frontend/e2e && npx playwright install chromium   # один раз
cd frontend && npm test             # 61 сценарий в браузере

# Анализ текста настоящей моделью: нужен поднятый сервер модели
cd backend && cargo test --test text_analysis -- --ignored --nocapture
```

Проверки работают на **отдельной базе** (`TEST_DATABASE_URL` в `backend/.env`), а браузерный прогон поднимает свой сервер и клиент на своих портах — рабочий стенд они не трогают. Подготовка тестовой базы — `CONTRIBUTING.md`.

7.7. Развёртывание стенда

Весь тренажёр поднимается на чистой ВМ одной командой через docker compose:

```
deploy/up.sh
```

Сервис	Что это	Наружу
`web`	nginx: собранный клиент, прокси `/api` и `/ws` на сервер	один порт (80)
`backend`	сервер тренажёра, release-сборка; ежесуточная копия базы	нет
`db`	PostgreSQL 16	нет
`model`	llama.cpp с патчем MTP и весами GigaChat	нет

При первом запуске скрипт создаёт `deploy/.env` со случайными паролем базы и ключом подписи токенов, сервер сам накатывает миграции и импортирует классификатор. Модель включается, только если найден файл весов; без него стенд работает на заглушке (раздел 7.5). Проверка стенда — `deploy/check.sh`, ничего не меняет.

Требования к ВМ: 6 ядер x86-64, 32 ГБ памяти с моделью (16 ГБ без неё), 40 ГБ диска, Ubuntu 22.04 или 24.04, видеокарта не нужна. Подробно — `deploy/README.md`.

---

8. Перечень использованных библиотек

Полные версии зафиксированы в `backend/Cargo.lock` и `frontend/apps/react/package-lock.json`.

8.1. Сервер — прямые зависимости

Библиотека	Версия	Лицензия	Назначение
tokio	1.53.1	MIT	асинхронная среда выполнения
axum	0.8.9	MIT	HTTP-сервер и маршрутизация
tower, tower-http	0.5.3, 0.6.11	MIT	промежуточные слои, статика, CORS
sqlx	0.8.6	MIT / Apache-2.0	доступ к PostgreSQL, миграции
serde, serde_json	1.0.229, 1.0.151	MIT / Apache-2.0	сериализация
argon2, password-hash	0.6.0, 0.6.1	MIT / Apache-2.0	хранение паролей
jsonwebtoken	11.1.0	MIT	токены доступа
reqwest	0.12.28	MIT / Apache-2.0	обращение к серверу модели
tokio-tungstenite	0.29.0	MIT	канал событий WebSocket
utoipa, utoipa-swagger-ui	5.5.0, 9.0.2	MIT / Apache-2.0	схема OpenAPI
calamine	0.36.1	MIT	чтение файлов классификатора
chrono	0.4.45	MIT / Apache-2.0	время и нормативы
uuid	1.26.1	Apache-2.0 / MIT	идентификаторы
tracing, tracing-subscriber	0.1.44, 0.3.23	MIT	журналирование
anyhow, thiserror	1.0.104, 2.0.20	MIT / Apache-2.0	обработка ошибок
rand	0.10.3	MIT / Apache-2.0	генерация значений
async-trait	0.1.92	MIT / Apache-2.0	трейты адаптеров моделей
dotenvy	0.15.7	MIT	чтение настроек
futures-util, http-body-util	0.3.34, 0.1.5	MIT	вспомогательные

Полный граф — **344 пакета**. Распределение лицензий: MIT и/или Apache-2.0 — 280, Unicode-3.0 — 18, остальные (BSD, ISC, Zlib, Unlicense, CDLA-Permissive) — 46. **Копилефт-лицензий, обязывающих раскрывать исходный код, в графе нет.**

8.2. Клиент — прямые зависимости

Библиотека	Версия	Лицензия	Назначение
react, react-dom	19.3.0	MIT	интерфейс
react-router-dom	7.18.4	MIT	маршрутизация
zustand	5.0.15	MIT	состояние
vite, @vitejs/plugin-react	8.3.0, 6.1.1	MIT	сборка
sass	1.104.1	MIT	стили
typescript	6.0.3	Apache-2.0	типизация
oxlint	1.83.0	MIT	статический анализ
@types/*	—	MIT	описания типов

Диаграммы аналитики нарисованы средствами SVG — сторонней библиотеки для графиков в поставке нет.

В дереве сборки присутствует `lightningcss` 1.33.0 под **MPL-2.0** (преобразователь CSS внутри Vite). Это инструмент сборки: в поставляемый клиент его код не попадает, изменения в него не вносились, поэтому требования MPL о раскрытии изменённых файлов не возникают.

8.3. Проверки (в поставку не входят)

Playwright (Apache-2.0) — сценарии в браузере.

8.4. Модель и развёртывание

Компонент	Лицензия
GigaChat 3.1 10B-A1.8B	MIT
llama.cpp	MIT
PostgreSQL	PostgreSQL License
nginx	BSD-2-Clause

Лицензия MIT у весов модели существенна: она разрешает коммерческое использование, в отличие от распространённых среди русскоязычных моделей лицензий с оговоркой NonCommercial, неприменимых для государственного заказчика.

Два патча к llama.cpp (`backend/docs/mtp-1-converter.patch`, `mtp-2-runtime.patch`) написаны в рамках этой работы и распространяются на условиях лицензии llama.cpp.

---

9. Состав документации репозитория

Файл	О чём
`README.md`	обзор, быстрый старт
`deploy/README.md`	развёртывание стенда на ВМ, эксплуатация
`BACKEND.md`	схема базы, контракт API, домен
`INTEGRATION.md`	встраивание в стороннюю систему
`PROVENANCE.md`	происхождение каждого набора данных и наши допущения
`OPEN-QUESTIONS.md`	вопросы к заказчику и принятые допущения
`CHAT-FINDINGS.md`	что уточнено в чате задачи и как это отражено в решении
`CONTRIBUTING.md`	правила работы с кодом, тестовая база
`backend/docs/MODEL-SERVER.md`	сборка и запуск сервера модели, замеры
`frontend/README.md`	архитектура клиента
`frontend/SCENARIOS.md`	сопоставление с экранами боевой системы
`frontend/DEFECTS.md`	найденные проверками дефекты