Тренажёр оператора ДДС города Москвы

Сопроводительная документация

Задача №9 Департамента по делам гражданской обороны, чрезвычайным ситуациям и пожарной безопасности города Москвы. Лидеры цифровой трансформации, 2026.

---

1. Назначение

Тренажёр готовит операторов дежурно-диспетчерских служб и Системы-112 к работе в боевой системе **ПОВ-112 (АРМ-112)**. Оба участка из ТЗ отрабатываются в интерфейсе, повторяющем боевой:

- **оператор 112** принимает учебный вызов: выясняет у заявителя обстоятельства, заполняет карточку происшествия, классифицирует его и оповещает службы;
- **диспетчер ДДС** получает поток карточек своей службы: принимает или мотивированно отклоняет, назначает бригаду, по докладам старшего ведёт статусы реагирования до завершения.

Преподаватель проводит занятия по группе, готовит учебные вызовы и видит аналитику. После каждого вызова курсант получает разбор с ценой каждой ошибки, прогноз своего результата и рекомендации — и то, и другое система потом проверяет фактом.

Ключевая особенность решения — **тренажёр отличает выясненное от угаданного**. Раздел 3.3 объясняет, почему это главная метрика подготовки оператора.

---

2. Состав решения

Компонент	Технология	Назначение
Веб-клиент	React 19, TypeScript, Vite	интерфейс АРМ-112 и учебный слой
Сервер приложения	Rust, axum, tokio	API, домен, оценка, фоновые задачи
Хранилище	PostgreSQL 16	классификатор, вызовы, занятия, журналы, настройки
Языковая модель	GigaChat 3.1 10B-A1.8B на llama.cpp	подготовка учебных вызовов, правка по переписке, сводки

Все четыре компонента разворачиваются на одной машине без выхода в интернет и без графического ускорителя — одной командой, раздел 7.7. Обоснование выбора — раздел 6.

Объём исходного кода: 13 877 строк Rust в 60 файлах, 5 302 строки TypeScript в 48 файлах, 25 миграций схемы базы.

3. Методы обработки данных

3.1. Классификация происшествия — детерминированная, без нейросети

Единый классификатор происшествий (ЕКП) — это таблица, где каждой комбинации признаков соответствует **ровно один** правильный ответ. Поэтому классификацию считает не модель, а прямой поиск по таблице:

```
ответы карты ──①──► признаки ──②──► позиция ЕКП ──③──► список оповещения
```

① Ответы опросной карты сопоставляются с признаками трёх уровней («где», «что именно», «уточнение»). ② По группе и признакам ищется позиция классификатора. Если незаполненный уровень признаков оставляет несколько позиций с разными исходами, система **не выбирает первую попавшуюся**, а называет варианты и просит уточнить — так же ведёт себя боевая система. ③ Позиция задаёт список оповещения. Службы, получающие лишь копию карточки (значения «карточка-112», «нет реагирования»), отделяются от реагирующих: оценка не должна штрафовать за то, что оператор их не вызвал.

В активной версии классификатора **1 283 позиции в 24 группах**, **134 593 строки матрицы оповещения**, 60 служб.

Такой выбор даёт воспроизводимость: эталон для учебного вызова не зависит от того, какая модель загружена и загружена ли вообще.

3.2. Опросные карты для всех типов происшествия

В выпадающем списке «Что случилось?» — **51 тип**, как в боевой системе (полный список передан экспертами в чате задачи). Опросная карта есть у **44** из них:

- **3 карты сняты с кадров боевой системы** (101 — пожар, 104 — газ, «Взрыв»): формулировки вопросов и вариантов дословные. Карта 101 снята по трём веткам — «Дом», «Улица» и «Транспорт»;
- **41 карта выведена из классификатора**: опросная карта боевой системы — это дерево признаков группы, и классификатор содержит его целиком. Подписи вопросов — заголовки столбцов классификатора, варианты — дословно из ячеек. Ничего не сочинено;
- **у 7 типов карты нет** («Внутренний звонок», «Нецелевой вызов», «Технический сбой» и др.): это виды обращений, а не происшествия, в классификаторе им не соответствует ни один признак. Интерфейс так и пишет, а не показывает пустую форму.

Карта **растёт по мере ответов**, как на кадрах боевой системы:

- варианты второго признака зависят от первого (`depends_on`): у «ДТП» одни, у «ДТП с пострадавшими» — другие; смена первого признака снимает неподходящие ответы на втором;

- вопрос целиком появляется только при нужном ответе (`show_when`): на пустом «Где» у пожара видны только «Где» и «Описание», после «Улица» — «Признак пожара», «Доступ», «Место происшествия», а «Описание правонарушения» — лишь после «Есть правонарушение».

Карты выводятся при каждом запуске сервера и при активации новой версии классификатора — поэтому смена версии не оставляет устаревших карт.

3.3. Оценка оператора 112 — три слоя

Разбор сравнивает три независимых слоя данных:

Слой	Что это
Скрытая истина	что на самом деле произошло, заложено в сценарий
Стенограмма	что заявитель действительно сообщил в разговоре
Карточка	что оператор ввёл в поля

Из сопоставления рождаются четыре вида замечаний с разным весом:

Вид	Вес	Смысл
`guessed`	1	значение верное, но заявитель его не сообщал — **угадал**
`extra`	1	вызвана лишняя служба
`missing`	2	служба не оповещена
`wrong`	3	значение не совпало с эталоном

Превышение норматива времени добавляет 2.

Замечание формулируется как последствие, а не как балл: не «−3 за поле „служба“», а «служба не оповещена — фактически не выехала».

Смысл метрики «угадал»: оператор, угадавший тип происшествия по первой фразе, в боевой обстановке ошибётся, как только вызов окажется нетипичным. На данных стенда доля угаданного составила **38 %** — то есть больше трети верных ответов курсанты не выясняли у заявителя.

3.4. Работа диспетчера ДДС: статусы, нормативы, бригада

Статусы реагирования идут строго по памятке ДДС: сначала «Принята» или «Не принята», затем «Начало реагирования» → «Прибытие» → «Проведение работ» → «Работы завершены» или «Отказ от выполнения работ». Порядок проверяется на сервере, а не только в интерфейсе. «Не принята» и «Отказ» без комментария сервер не принимает: заказчик требует мотивированного отказа. Поля, которые заполнил оператор 112, диспетчер ДДС не редактирует — только свои статусы и комментарии к ним.

Нормативы — по ответу заказчика в чате задачи (27.09.2026):

Норматив	Значение	Отсчёт
Открыть карточку	30 с	с момента появления карточки в строке сообщений
Первая запись: статус и текст	3 мин	см. ниже

Открытие карточки фиксируется системной отметкой «Получена службой». Точка отсчёта трёх минут в ответе заказчика («3 минуты на открытие карточки и добавление первой записи») однозначно не закреплена; мы считаем от поступления карточки. Остальные временные показатели заказчик не определял: работы могут идти часами и днями.

Статус карточки не хранится как состояние конечного автомата, а **выводится** из состояния служб и прошедшего времени. Фоновая задача (тик 5 секунд) пересчитывает статусы и переводит карточки в «Не оповещено» (норматив открытия или первой записи истёк) и «Не завершено» (48 часов, памятка ДДС). Запись условная — по прежнему статусу, поэтому два экземпляра сервера не запишут переход дважды.

Бригада. По ответам заказчика бригаду диспетчер выбирает вручную, а сведения о ходе работ получает от старшего: тот звонит с докладом сам, или диспетчер сам звонит ему. В тренажёре живут оба варианта:

- этапы работ бригады наступают по шкале от момента назначения — это скрытая истина, как факты заявителя у оператора 112;
- старший докладывает о наступившем этапе с задержкой; диспетчер, который позвонил раньше, узнаёт раньше. Доклад называет только этап («прибыли на место») — обстановку на месте мы не придумываем.

Разбор диспетчера ДДС проверяет требование памятки «статусы по факту получения информации»:

Замечание	Вес	Смысл
статус раньше доклада	2	«не по факту» — аналог «угадал» у оператора 112
доклад без статуса	2	служба 112 и соседние ДДС не видят хода работ
принята, бригада не назначена	2	на место никто не выехал
статус позже доклада сверх норматива	1	в карточке устаревшая картина
карточка открыта позже 30 с	1	норматив заказчика
первая запись позже 3 мин или без текста	1	норматив заказчика

Что здесь — наше допущение, а не норматив заказчика. Число учебных бригад (3), шкала этапов (выезд 20 с, путь 40 с, начало работ 20 с, работы 60 с), задержка доклада (25 с) и норматив обновления статуса после доклада (30 с) заказчик не называл. Шкала сжата под учебное занятие, одна на все службы — заказчик сам попросил «универсальный алгоритм для всех». Всё вынесено в настройки и перечислено в `PROVENANCE.md` («Наши допущения») и `OPEN-QUESTIONS.md` (вопрос 18).

3.5. Прогноз результата и его проверка

Критерий экспертизы просит не прогноз, а **его проверку** — сравнение прогнозных значений с реальными. Поэтому устройство такое:

1. **Прогноз фиксируется до начала вызова** и задним числом не переписывается; факт проставляется после разбора. Точность показывается только по фактически сделанным прогнозам.
2. **Модель — гребневая регрессия**, а не нейросеть: данных мало, сложная модель переобучится, а на разборе нужно показать, из чего сложился прогноз. Признаки — по последним разборам курсанта: средний балл, тренд, доля угаданного, доля превышений норматива, опыт, средний балл на той же группе классификатора. Коэффициенты считаются решением нормальных уравнений, без внешних библиотек.
3. **Рядом всегда базовая линия** — средний балл курсанта. Пока пар «прогноз — факт» меньше 30, модель не обучается и прогноз делает базовая линия; при истории меньше 3 разборов прогноз помечается недостоверным.
4. Достоверность — средняя абсолютная ошибка, доля попаданий в допуск (по умолчанию ±10 баллов) и та же ошибка у базовой линии: видно, стоит ли модель своих сложностей.

Курсант видит свой прогноз с разложением по признакам в разборе, преподаватель — достоверность прогноза по группе в аналитике.

3.6. Рекомендации курсанту и проверка их исполнения

Рекомендация сама по себе — декларация, поэтому проверяется так же, как прогноз. После разбора система ищет **повторяющиеся** ошибки: одно и то же поле с тем же видом замечания в последних разборах. Текст рекомендации собирается только из замечаний разбора — подпись поля плюс заготовка по виду ошибки, — модель его не пишет.

Рекомендация фиксируется с временем. В первом следующем разборе, где ошибка могла повториться, ставится вердикт: ушла или нет. Доля сработавших — измеренная величина, и рядом базовая линия: как часто та же повторяющаяся ошибка уходит сама, без рекомендации.

Пороги — **наше допущение** (`OPEN-QUESTIONS.md`, вопрос 19): окно 5 разборов, повтор не меньше 2 раз, открытых рекомендаций не больше 3, о доле судим не раньше 5 проверок. Сравнение с базовой линией строже к рекомендациям, чем к ней самой: рекомендации достаются самым частым ошибкам. На экране это сказано.

3.7. Языковая модель — только текст

Модель отвечает за то, что нельзя посчитать: черновики учебных вызовов (первая фраза заявителя, его ответы на вопросы), правку вызова по переписке с преподавателем, словесные сводки по группе. **Эталон для оценки она не считает никогда** — его считает классификатор. Во время занятия курсанта модель не вызывается: ответы заявителя подготовлены заранее и выверены преподавателем.

При подготовке учебного вызова конвейер устроен так:

1. признаки выбираются из **закрытого словаря** опросной карты;

2. ответы, которых нет в словаре, отбрасываются;
3. классификатор считает эталон;
4. если он жалуется (например, «уточните признак второго уровня»), его жалоба возвращается модели как замечание, и шаг повторяется;
5. только после этого модель пишет текст легенды и скрытых фактов.

Ответ модели ограничен **схемой JSON на уровне декодирования** (`response_format: json_schema`): движок отбрасывает токены, нарушающие схему, поэтому структурно неверный ответ невозможен.

Где работает модель. Сервер приложения обращается к ней по протоколу, совместимому с OpenAI API; адрес задаётся переменной `ML_BASE_URL`. В поставке это локальный llama.cpp на той же машине — внешних обращений нет, данные никуда не уходят. Тот же адрес можно направить на другой совместимый сервер (vLLM, Ollama) во внутреннем контуре, не меняя кода. При развёртывании через `deploy/up.sh` достаточно указать `ML_BASE_URL` в `deploy/.env` — тогда свой контейнер модели не поднимается.

3.8. Исходные данные

Все данные, на которых работает тренажёр, взяты из материалов задачи и ответов экспертов. Их происхождение построчно зафиксировано в `PROVENANCE.md`:

- **ЕКП** — файлы классификатора двух версий (v046_11 от 15.11.2024 и v046_24 с корректировкой МВД и Департамента), импортированы целиком;
- **учебные вызовы** — 96 обращений, разобранных из 32 бумажных билетов; у всех 96 разобран телефон, у 57 — ФИО заявителя, у 25 — скрытый адрес. Из них готовятся учебные вызовы (раздел 4.5);
- **интерфейс** — снят по скриншотам боевой системы, сопоставление кадров описано в `frontend/SCENARIOS.md`; полный список типов происшествия, ветки карты 101 и справочник служб — по материалам, переданным экспертами в чате задачи.

Где данных заказчика не хватило, параметр вынесен в настройки и помечен как наше допущение (`PROVENANCE.md`, «Наши допущения»). Синтетических данных, выданных за данные заказчика, в поставке нет.

---

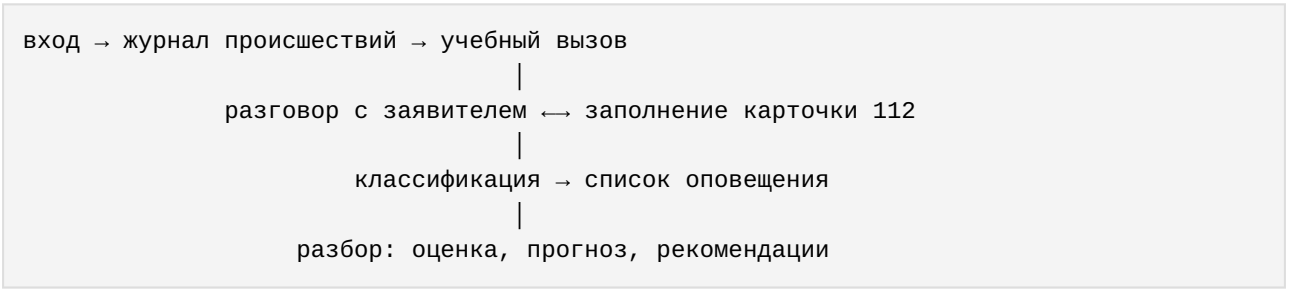
4. Функциональная архитектура

4.1. Роли

Роль	Доступ
Курсант	учебные вызовы, карточки своей службы, своя история, разбор, прогноз, рекомендации
Преподаватель	занятия, подготовка вызовов, группы, аналитика по группе
Администратор	версии классификатора, учётные записи, настройки, системные журналы

Разграничение проверяется на сервере при каждом запросе; интерфейс скрывает недоступные разделы, но не является средством защиты.

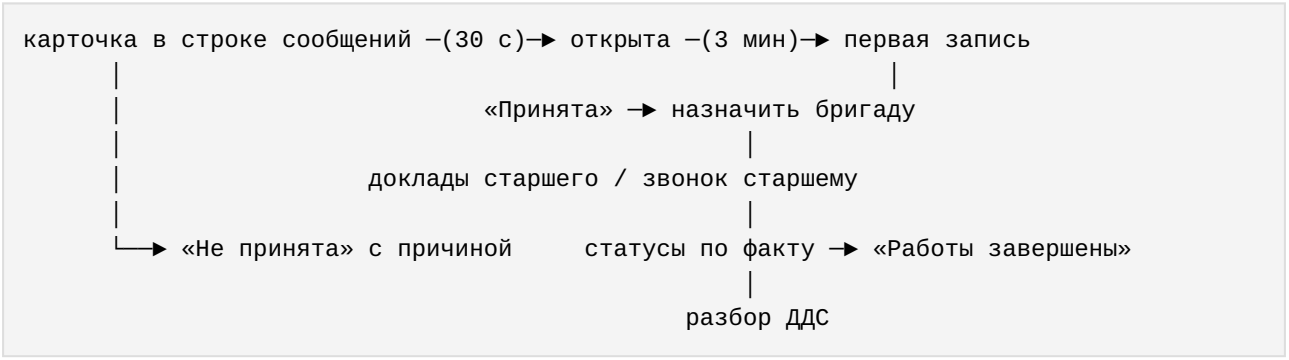
4.2. Оператор 112



Курсант задаёт заявителю вопросы; ответ помечает факт выясненным — на этом держится разбор «узнал или угадал». Ввод в карточку уходит на сервер пакетами; правки в пределах одного окна **сливаются вглубь**, а не затирают друг друга. При обрыве сети пакет повторяется.

4.3. Диспетчер ДДС

Сохранённая оператором 112 карточка приходит в журнал каждой службы из списка оповещения. Диспетчер работает с несколькими карточками одновременно, как в текущей работе: пока он занят одной, время идёт и у ожидающих.



Звонок старшему и входящие доклады приходят в карточку ДДС текстом.

4.4. Занятие преподавателя

Порядок — из ТЗ (§10, «Проведение практического занятия»): преподаватель создаёт занятие для группы, выбирает режим и категории происшествий под тему, запускает, следит за ходом и завершает в любой момент.

Режим	Что получает группа
Приём вызова (112)	учебные вызовы по выбранным категориям; пока идёт занятие, курсант видит только их
Работа ДДС	карточки по службам курсантов — созданные системой, заполненные курсантами на занятиях 112 или вперемешку; до 5 карточек на службу, в случайном порядке

В режиме ДДС карточки занятия **поступают потоком**: с интервалом, который задаёт преподаватель при создании занятия, — а не все сразу. Ход занятия виден по каждому курсанту: сколько взято, сколько доведено до разбора, средний балл. При завершении недоработанные вызовы закрываются.

4.5. Подготовка учебных вызовов

Преподаватель запускает подготовку вызовов из билетов (конвейер раздела 3.7) и доводит каждый перепиской с моделью: «поменяй ФИО», «добавь, что из мусоропровода идёт пламя», «сделай первую фразу короче». Модель отвечает репликой и правкой; правка применяется к вызову, эталон пересчитывается классификатором. В переписке показывается, что **фактически** изменилось, — по сравнению вызова до и после, а не со слов модели. Сыгранные факты не удаляются, а снимаются с учёта, чтобы не ломать уже пройденные разборы.

Готовый вызов преподаватель утверждает — до утверждения курсанты его не видят. **Преподаватель — конечный валидатор**, как и просит заказчик.

Как правки преподавателя влияют на модель — ровно так: переписка по вызову сохраняется, и последние ходы подаются модели в контекст при следующей правке того же вызова, поэтому «нет, короче» имеет смысл. Весов модели правки не меняют, и на подготовку других вызовов не переносятся. Дообучения модели на правках преподавателя в поставке нет — как это должно выглядеть, заказчик пока не определил.

4.6. Аналитика

Диаграммы (тепловая карта ошибок, динамика, воронка, виды замечаний) строятся из статистики занятий средствами SVG, без сторонних библиотек. Там же — достоверность прогноза и доля сработавших рекомендаций по группе, рядом с базовыми линиями. Словесную сводку по группе формулирует модель — но **числа в неё подаются уже посчитанными**, в виде именованных агрегатов.

4.7. Настраиваемые параметры

Нормативы, параметры прогноза, рекомендаций и шкалы бригады хранятся в таблице настроек, а не в коде. Администратор меняет их через API (`PATCH /api/settings/{key}`); у каждого параметра есть допустимые пределы, значение вне их сервер отклоняет.

---

5. Компонентная архитектура

5.1. Сервер

```
api/        HTTP-обработчики, схема OpenAPI
domain/     классификатор, статусы, оценка, бригада, прогноз, рекомендации
ingest/     импорт классификатора и билетов, вывод опросных карт
reports/    отчёты, прогноз и рекомендации над данными базы
```

```
jobs/       фоновые задачи: сторож нормативов, доклады бригад, очередь модели
ml/         адаптеры моделей: HTTP-сервер модели и заглушка
```

Доменный слой не знает ни о HTTP, ни о моделях: классификатор, оценка, разбор ДДС, прогноз и рекомендации — чистые функции над данными. Поэтому все **229 серверных проверок** выполняются без поднятия модели.

Описание API машиночитаемо (OpenAPI, utoipa). Отдельная проверка читает список маршрутов из исходного кода и **падает при расхождении** со схемой.

5.2. Клиент

Слоистая раскладка (Feature-Sliced Design): `shared` → `entities` → `widgets` → `pages`. Состояние — zustand, стили — модули SCSS, маршрутизация — HashRouter (стенд отдаётся статикой без настройки переписывания путей).

Канал событий WebSocket с переподключением по возрастающей задержке. Канал — **ускорение, а не источник истины**: при его отказе интерфейс продолжает работать на обычных запросах.

5.3. Сервер модели

llama.cpp в режиме сервера, совместимого с OpenAI API. Подробности — `backend/docs/MODEL-SERVER.md`.

---

6. Условия и ограничения

6.1. Целевой стенд

Процессор Intel Core i7 или Xeon, не менее 6 ядер; 32 ГБ оперативной памяти; **графический ускоритель не предусмотрен**. Это задано системными требованиями, и из этого следует весь выбор в разделе 3.

6.2. Что из этого следует

Модель на процессоре — узкое место. Выбрана **GigaChat 3.1 10B-A1.8B**: из десяти миллиардов параметров на каждом токене работают 1,8 миллиарда (архитектура со смесью экспертов, 64 эксперта, используются 4). Скорость на процессоре определяется активными параметрами, а не общим размером, поэтому модель отвечает как небольшая, а знает как крупная. Лицензия MIT.

Дополнительно включено **спекулятивное декодирование на блоке MTP** (multi-token prediction), встроенном в модель. Поддержки этого режима для данной архитектуры в llama.cpp не было — она добавлена двумя патчами, которые приложены к поставке (`backend/docs/mtp-*.patch`).

Измеренный результат на 6 потоках: **10,3 → 14,8 токенов в секунду, прирост 44 %**. Существенно, что `--spec-draft-n-max 1`: при значении по умолчанию 3 проверка отбрасывала большую часть черновика (доля принятых токенов 30 %), при 1 — принимается 73 %.

Оговорки к замеру. Мерили на AMD EPYC 7532 с **восемью каналами памяти**; ограничены были потоки (6), но не каналы. Генерация на процессоре упирается в пропускную способность памяти, а не в ядра, поэтому это **потолок, а не пол**: на настольном i7 с двухканальной памятью скорость будет ниже. На такой машине мы не мерили и цифру не называем (`OPEN-QUESTIONS.md`, вопрос 11). Сравнивались два прогона при одинаковой нагрузке, а не серия: порядок величины достоверен, вторая значащая цифра — нет.

Скорость модели не влияет на нормативы ТЗ: модель не вызывается во время занятия курсанта (раздел 3.7), а подготовка вызовов и сводки идут в фоновой очереди.

6.3. Требования ТЗ к производительности — что к чему относится

Требование ТЗ (§7)	К чему относится	У нас
отклик интерфейса ≤ 2 с при 100 пользователях	запросы к серверу приложения	модель в этот путь не входит; подбор служб по признакам — прямой поиск по таблице
задержка VoIP ≤ 150 мс	передача голоса	это не время ответа языковой модели; голосового канала в текущей поставке нет (раздел 6.4)
отчёт ≤ 30 с	аналитические отчёты	считаются в фоновой очереди из базы
сбой сети до 30 с	восстановление сессии	пакеты ввода повторяются, канал событий переподключается

6.4. Ограничения решения

- **Голос.** В текущей поставке разговор ведётся текстом: курсант выбирает вопросы заявителю, доклады старшего бригады приходят текстом. Точки подключения распознавания и синтеза речи заложены (`ml/`); голосовой канал — отдельная работа, в поставку на момент написания не вошёл.
- **Подбор служб только по типу происшествия.** По ответу заказчика службы в боевой системе подтягиваются ещё и по району обслуживания и подчинённости объекта (школа → ДДС департамента образования, управы, округа). Справочника «адрес → службы», по словам заказчика, нет в природе; территориальных получателей тренажёр не подбирает (`OPEN-QUESTIONS.md`, вопрос 15).
- **Нет сообщения ДДС в 112 об ошибке в карточке.** По ответу заказчика диспетчер узнаёт об ошибке из звонка бригады и сообщает в 112 по телефону. Эталонных примеров ошибок заказчик не дал, поэтому ошибки в карточки ДДС тренажёр не подкладывает.
- **Дообучения модели по правкам преподавателя нет** (раздел 4.5).
- **Какая версия классификатора эталонная** (v046_24 или v046_11), заказчик ещё не ответил. Активна v046_24; администратор может загрузить и активировать другую, разницу между версиями и затронутые учебные вызовы отдаёт API (`/api/classifier/versions/{a}/diff/{b}`, `…/impact`).
- **Сводка по группе считается около минуты** — числа берёт база, но формулирует их модель на процессоре.
- **Тренажёр не подключается к боевой ПОВ-112.** Он воспроизводит её интерфейс и логику по материалам задачи; обмена данными с действующей системой нет и не предполагается.

- **Часть решений принята при неполных исходных данных.** Все такие места перечислены в `OPEN-QUESTIONS.md` с указанием, что именно неизвестно и какое допущение сделано, — а не замаскированы.

---

7. Сборка, установка и запуск

Для стенда — раздел 7.7, одна команда. Разделы 7.1–7.6 — локальный запуск для разработки.

7.1. Что должно быть на машине

Компонент	Версия	Проверено на
Rust	см. примечание	1.98.1
Node.js	20.19+	20.20.0
PostgreSQL	14+	16 (в контейнере)
Docker	любая	для базы; необязателен

Нижняя граница версии Rust не проверялась: указана та, на которой решение собрано. Редакция языка — 2021.

7.2. База данных

```
docker run -d --name arm112-db \
  -e POSTGRES_USER=arm112 -e POSTGRES_PASSWORD=arm112 \
  -e POSTGRES_DB=arm112 -p 5432:5432 postgres:16
```

Схема, учебные учётные записи и выверенные учебные вызовы разворачиваются миграциями при первом запуске сервера.

7.3. Сервер приложения

```
cd backend
cp .env.example .env          # при необходимости поправить DATABASE_URL
cargo run --release           # http://localhost:8080, накатит миграции
```

Классификатор ставится отдельной командой (один раз), после чего сервер нужно перезапустить — опросные карты выводятся из классификатора при старте:

```
cargo run --release --bin import_classifier -- \
  ../task/Классификатор_происшествий_v_046_24*.xlsx "v046_24"
```

Описание API после запуска: `http://localhost:8080/api/docs`. Учётные записи: `admin`, `teacher1`, `student1`…`student5` (курсанты разных служб), пароль у всех `arm112`.

7.4. Веб-клиент

```
cd frontend
npm run install:all
npm run build                # сборка в apps/react/dist
npm run dev                  # разработка, http://localhost:5173
```

Собранный клиент — статические файлы, отдаётся любым веб-сервером.

7.5. Сервер модели

Подробная процедура, включая наложение патчей MTP и переквантование весов, — `backend/docs/MODEL-SERVER.md`. Кратко:

```
llama-server -m GigaChat3.1-10B-A1.8B-q4_K_M.gguf \
  --host 127.0.0.1 --port 8090 -t 6 -c 8192 \
  --spec-type draft-mtp --spec-draft-n-max 1
```

Сервер приложения подключается к нему переменными окружения:

```
ML_PROVIDER=http
ML_BASE_URL=http://127.0.0.1:8090
```

Без них сервер работает на заглушке: журнал, карточки, классификация, занятия, оценка, разбор ДДС, прогноз и рекомендации полностью функциональны; нет только подготовки и правки учебных вызовов моделью и словесной сводки по группе.

7.6. Проверки

```
cd backend && cargo test            # 229 проверок
cd frontend/e2e && npx playwright install chromium   # один раз
cd frontend && npm test             # 54 сценария в браузере
```

Проверки работают на **отдельной базе** (`TEST_DATABASE_URL` в `backend/.env`), а браузерный прогон поднимает свой сервер и клиент на своих портах — рабочий стенд они не трогают. Подготовка тестовой базы — `CONTRIBUTING.md`.

7.7. Развёртывание стенда

Весь тренажёр поднимается на чистой ВМ одной командой через docker compose:

```
deploy/up.sh
```

Сервис	Что это	Наружу
`web`	nginx: собранный клиент, прокси `/api` и `/ws` на сервер	один порт (80)

Сервис	Что это	Наружу
`backend`	сервер тренажёра, release-сборка; ежесуточная копия базы	нет
`db`	PostgreSQL 16	нет
`model`	llama.cpp с патчем MTP и весами GigaChat	нет

При первом запуске скрипт создаёт `deploy/.env` со случайными паролем базы и ключом подписи токенов, сервер сам накатывает миграции и импортирует классификатор. Модель включается, только если найден файл весов; без него стенд работает на заглушке (раздел 7.5). Проверка стенда — `deploy/check.sh`, ничего не меняет.

Требования к ВМ: 6 ядер x86-64, 32 ГБ памяти с моделью (16 ГБ без неё), 40 ГБ диска, Ubuntu 22.04 или 24.04, видеокарта не нужна. Подробно — `deploy/README.md`.

---

8. Перечень использованных библиотек

Полные версии зафиксированы в `backend/Cargo.lock` и `frontend/apps/react/package-lock.json`.

8.1. Сервер — прямые зависимости

Библиотека	Версия	Лицензия	Назначение
tokio	1.53.1	MIT	асинхронная среда выполнения
axum	0.8.9	MIT	HTTP-сервер и маршрутизация
tower, tower-http	0.5.3, 0.6.11	MIT	промежуточные слои, статика, CORS
sqlx	0.8.6	MIT / Apache-2.0	доступ к PostgreSQL, миграции
serde, serde_json	1.0.229, 1.0.151	MIT / Apache-2.0	сериализация
argon2, password-hash	0.6.0, 0.6.1	MIT / Apache-2.0	хранение паролей
jsonwebtoken	11.1.0	MIT	токены доступа
reqwest	0.12.28	MIT / Apache-2.0	обращение к серверу модели
tokio-tungstenite	0.29.0	MIT	канал событий WebSocket
utoipa, utoipa-swagger-ui	5.5.0, 9.0.2	MIT / Apache-2.0	схема OpenAPI
calamine	0.36.1	MIT	чтение файлов классификатора
chrono	0.4.45	MIT / Apache-2.0	время и нормативы
uuid	1.26.1	Apache-2.0 / MIT	идентификаторы
tracing, tracing-subscriber	0.1.44, 0.3.23	MIT	журналирование
anyhow, thiserror	1.0.104, 2.0.20	MIT / Apache-2.0	обработка ошибок
rand	0.10.3	MIT / Apache-2.0	генерация значений
async-trait	0.1.92	MIT / Apache-2.0	трейты адаптеров моделей
dotenvy	0.15.7	MIT	чтение настроек

Библиотека	Версия	Лицензия	Назначение
futures-util, http-body-util	0.3.34, 0.1.5	MIT	вспомогательные

Полный граф — **344 пакета**. Распределение лицензий: MIT и/или Apache-2.0 — 280, Unicode-3.0 — 18, остальные (BSD, ISC, Zlib, Unlicense, CDLA-Permissive) — 46. **Копилефт-лицензий, обязывающих раскрывать исходный код, в графе нет.**

8.2. Клиент — прямые зависимости

Библиотека	Версия	Лицензия	Назначение
react, react-dom	19.3.0	MIT	интерфейс
react-router-dom	7.18.4	MIT	маршрутизация
zustand	5.0.15	MIT	состояние
vite, @vitejs/plugin-react	8.3.0, 6.1.1	MIT	сборка
sass	1.104.1	MIT	стили
typescript	6.0.3	Apache-2.0	типизация
oxlint	1.83.0	MIT	статический анализ
@types/*	—	MIT	описания типов

Диаграммы аналитики нарисованы средствами SVG — сторонней библиотеки для графиков в поставке нет.

В дереве сборки присутствует `lightningcss` 1.33.0 под **MPL-2.0** (преобразователь CSS внутри Vite). Это инструмент сборки: в поставляемый клиент его код не попадает, изменения в него не вносились, поэтому требования MPL о раскрытии изменённых файлов не возникают.

8.3. Проверки (в поставку не входят)

Playwright (Apache-2.0) — сценарии в браузере.

8.4. Модель и развёртывание

Компонент	Лицензия
GigaChat 3.1 10B-A1.8B	MIT
llama.cpp	MIT
PostgreSQL	PostgreSQL License
nginx	BSD-2-Clause

Лицензия MIT у весов модели существенна: она разрешает коммерческое использование, в отличие от распространённых среди русскоязычных моделей лицензий с оговоркой NonCommercial, неприменимых для государственного заказчика.

Два патча к llama.cpp (`backend/docs/mtp-1-converter.patch`, `mtp-2-runtime.patch`) написаны в рамках этой работы и распространяются на условиях лицензии llama.cpp.

---

9. Состав документации репозитория

Файл	О чём
`README.md`	обзор, быстрый старт
`deploy/README.md`	развёртывание стенда на ВМ, эксплуатация
`BACKEND.md`	схема базы, контракт API, домен
`INTEGRATION.md`	встраивание в стороннюю систему
`PROVENANCE.md`	происхождение каждого набора данных и наши допущения
`OPEN-QUESTIONS.md`	вопросы к заказчику и принятые допущения
`CHAT-FINDINGS.md`	что уточнено в чате задачи и как это отражено в решении
`CONTRIBUTING.md`	правила работы с кодом, тестовая база
`backend/docs/MODEL-SERVER.md`	сборка и запуск сервера модели, замеры
`frontend/README.md`	архитектура клиента
`frontend/SCENARIOS.md`	сопоставление с экранами боевой системы
`frontend/DEFECTS.md`	найденные проверками дефекты