ДЕПАРТАМЕНТ ПО ДЕЛАМ ГРАЖДАНСКОЙ ОБОРОНЫ, ЧРЕЗВЫЧАЙНЫМ СИТУАЦИЯМ И ПОЖАРНОЙ БЕЗОПАСНОСТИ ГОРОДА МОСКВЫ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

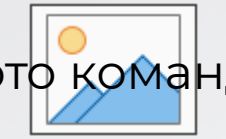


Тренажёр оператора ДДС и АРМ-112 с ИИ

Задача №9 · Департамент ГОЧСиПБ города Москвы

Команда [ЗАПОЛНИТЬ: название команды]

Фото команды



О команде

- **Капитан:** [ЗАПОЛНИТЬ: ФИО, специальность]
- **Кол-во участников:** [ЗАПОЛНИТЬ: число] человек
- **Краткое описание:**
  - *[ЗАПОЛНИТЬ: как образовалась команда]*
  - *[ЗАПОЛНИТЬ: место работы/учёбы участников]*
- **Город и регион:** [ЗАПОЛНИТЬ: город и регион]

Краткое описание решения:

Веб-тренажёр в интерфейсе боевой ПОВ-112: оператор 112 принимает учебный вызов и заполняет карточку, диспетчер ДДС ведёт реагирование бригады. Эталон считает классификатор ЕКП; нейросети, голос и проверка текста работают локально, в закрытом контуре.

Уникальность решения:

Проверяем то, что просил заказчик: сказанное заявителем против заполненного курсантом. Нейросеть объясняет ошибки цитатами, которые проверяет код; прогноз и рекомендации сверяются с фактом.

КОМАНДА

ПРОЕКТ МЭРА МОСКВЫ | БИЗНЕС МОСКВЫ | РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА | ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

[ЗАПОЛНИТЬ: Имя Фамилия]

- [ЗАПОЛНИТЬ: роль в команде]
- [ЗАПОЛНИТЬ: ник в мессенджере]
- [ЗАПОЛНИТЬ: телефон]
- [ЗАПОЛНИТЬ: место работы/учёбы]

[ЗАПОЛНИТЬ: Имя Фамилия]

- [ЗАПОЛНИТЬ: роль в команде]
- [ЗАПОЛНИТЬ: ник в мессенджере]
- [ЗАПОЛНИТЬ: телефон]
- [ЗАПОЛНИТЬ: место работы/учёбы]

[ЗАПОЛНИТЬ: Имя Фамилия]

- [ЗАПОЛНИТЬ: роль в команде]
- [ЗАПОЛНИТЬ: ник в мессенджере]
- [ЗАПОЛНИТЬ: телефон]
- [ЗАПОЛНИТЬ: место работы/учёбы]

[ЗАПОЛНИТЬ: Имя Фамилия]

- [ЗАПОЛНИТЬ: роль в команде]
- [ЗАПОЛНИТЬ: ник в мессенджере]
- [ЗАПОЛНИТЬ: телефон]
- [ЗАПОЛНИТЬ: место работы/учёбы]

[ЗАПОЛНИТЬ: Имя Фамилия]

- [ЗАПОЛНИТЬ: роль в команде]
- [ЗАПОЛНИТЬ: ник в мессенджере]
- [ЗАПОЛНИТЬ: телефон]
- [ЗАПОЛНИТЬ: место работы/учёбы]

ИСТОРИЯ КОМАНДЫ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Краткая история команды:

01

[ЗАПОЛНИТЬ: как собрались, участвовали ли вместе в хакатонах и проектах, интересные факты о команде]

Почему вы выбрали именно эту задачу из предложенных на хакатоне?

02

[ЗАПОЛНИТЬ: что вдохновило в этой задаче]

С какими основными сложностями или вызовами вы столкнулись и как их преодолели?

03

Требования уточнялись по ходу: нормативы ДДС заказчик определил 27.09 — перестроили отсчёт времени и поток карточек. Модель должна работать без видеокарты — добавили в llama.cpp поддержку MTP для GigaChat 3.1 (+44 % скорости). Опросных карт в материалах было три — ещё 41 вывели из классификатора, ничего не сочиняя.

[ЗАПОЛНИТЬ: личные истории команды, если есть]

КОРОТКО О РЕШЕНИИ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Техническая суть решения

- Сервер на Rust (axum) и PostgreSQL, клиент на React; закрытый контур, развёртывание одной командой.
- Эталон — детерминированно по классификатору ЕКП (1 283 позиции).
- Нейросетевая оценка: сказанное заявителем против заполненного, каждое замечание — с цитатой, которую проверяет код.
- ДДС по ответам заказчика: поток карточек, 30 с / 3 мин, бригада, голос со старшим и начальником.
- Два профиля моделей: CPU — GigaChat 3.1 и кросс-энкодер, GPU — Gemma 4; адрес модели — одна переменная.

Маркетинговая суть решения

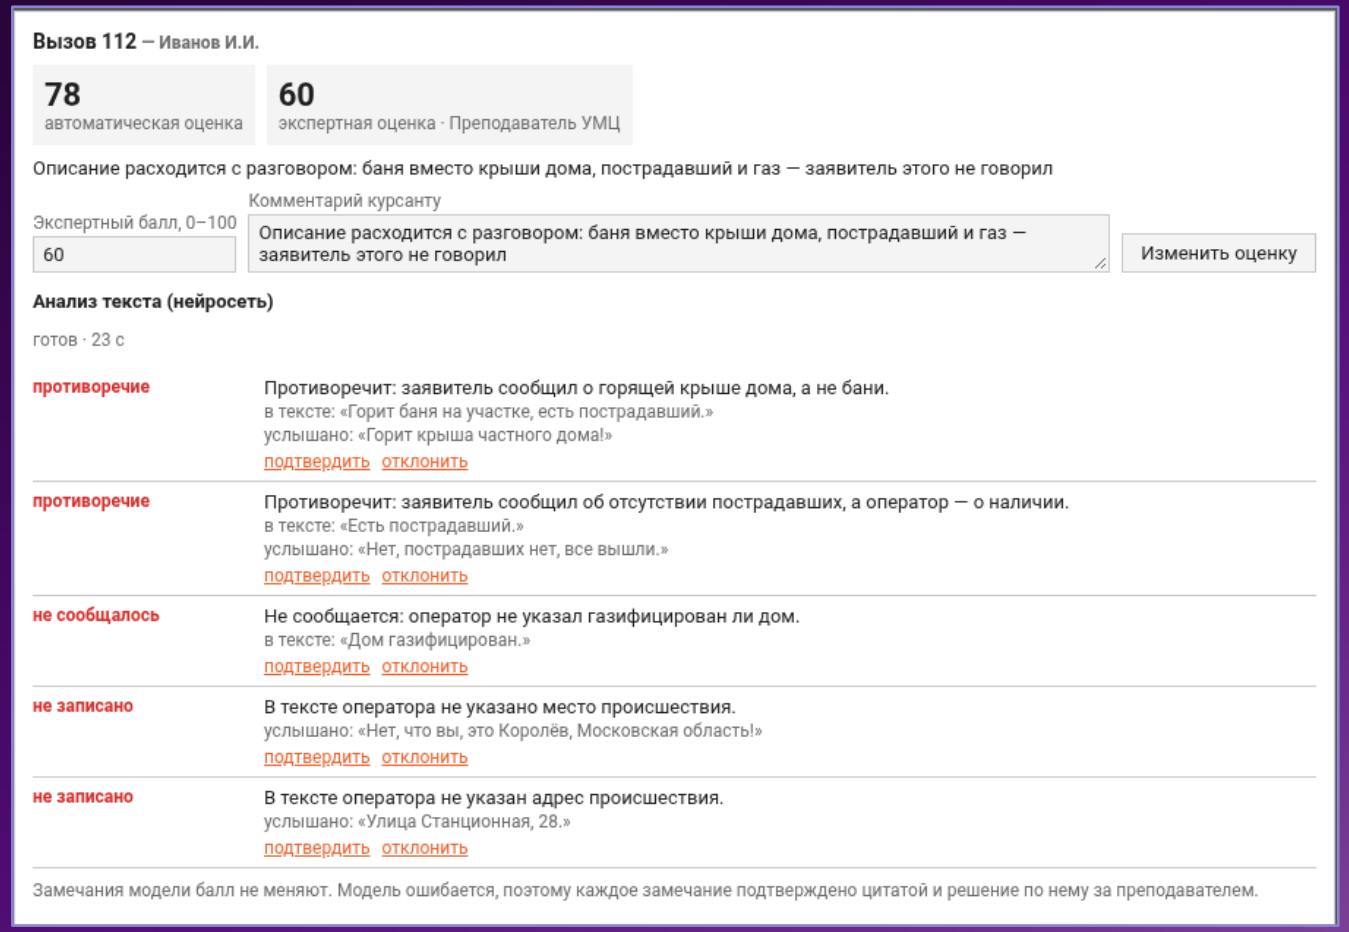
- Для учебного центра: подготовка операторов 112 и ДДС на копии боевого интерфейса, без доступа к боевой системе.
- Преподаватель готовит вызовы с моделью, проводит занятия, марафон и блиц, ставит экспертную оценку.
- Аналитика группы: ошибки, прогноз результата и рекомендации — каждое сверено с фактом и базовой линией.
- Развитие: подбор служб по территории — после справочника заказчика; SIP-телефония.

КАРТА СООТВЕТСТВИЯ: ВОПРОС → ОТВЕТ

Что спрашивают эксперты и заказчик	Откуда	Слайд	Статус
Оценка действий на основе нейросетевого анализа, анализ ручного ввода	ТЗ, постановка задачи	7	**да**
Сказанное против заполненного, какие службы выбраны	Q&A, чат № 642	7	**да**
Карточка и реестр похожи на 100 %, цвета и конфигурация	Чат № 679, 680	8	**да**
Одна учётка, две мини-роли: оператор 112 и диспетчер ДДС	Чат № 624, 628	9	**да**
ДДС: поток карточек, 30 с / 3 мин, статусы, бригада вручную	Чат № 684, 701, 709, 781	10	**да**
Голос ДДС со старшим бригады и начальником	Чат № 781; Q&A № 576, 638	11	**да**
Разговор с заявителем — «будет плюсом»	Чат № 781	12	**сверх MVP**
Прогноз и его достоверность	Критерии ТЗ, п. 3	13	**частично — на малых данных ≈ среднему**
Рекомендации и проверка их исполнения	Критерии ТЗ, п. 3–4	14	**частично — механизм, не польза**
Дополнительные настраиваемые параметры	Критерии ТЗ, п. 3	15	**да**
Объективность диаграмм	Критерии ТЗ, п. 3	16	**частично — тесты не отделены**
Преподаватель: контроль, автоматическая + экспертная оценка	ТЗ, роль преподавателя	17	**да**
Дообучение по поправкам преподавателя	Чат № 781	17	**частично**
Закрытый контур, адрес локальной модели, железо из ТЗ	ТЗ; чат № 710, 746	18	**да**
Скорость работы	Критерии ТЗ, п. 2	19	**да**
Нефункциональные требования: 100 польз., 20 сессий, сбой сети	ТЗ, §7	20	**да**
Интеграция в другие системы	Критерии ТЗ, п. 2	21	**да**
Качество кода и документация	Критерии ТЗ, п. 2 и 4	22	**да**
Службы по району обслуживания и подчинённости	Чат № 690	23	**нет — ограничение**

Требование: критерии предварительной и финальной экспертизы ТЗ; ответы заказчика и организаторов в чате задачи №9 (номера сообщений); сессия вопросов и ответов

НЕЙРОСЕТЕВАЯ ОЦЕНКА: СКАЗАННОЕ ПРОТИВ ЗАПОЛНЕННОГО



Вызов 112 — Иванов И.И.

78	60
автоматическая оценка	экспертная оценка · Преподаватель УМЦ

Описание расходится с разговором: баня вместо крыши дома, пострадавший и газ — заявитель этого не говорил

Экспертный балл, 0–100: 60

Комментарий курсанту: Описание расходится с разговором: баня вместо крыши дома, пострадавший и газ — заявитель этого не говорил

Изменить оценку

Анализ текста (нейросеть)

готов · 23 с

противоречие	Противоречит: заявитель сообщил о горящей крыше дома, а не бани. в тексте: «Горит баня на участке, есть пострадавший.» услышано: «Горит крыша частного дома!» подтвердить отклонить
противоречие	Противоречит: заявитель сообщил об отсутствии пострадавших, а оператор — о наличии. в тексте: «Есть пострадавший.» услышано: «Нет, пострадавших нет, все вышли.» подтвердить отклонить
не сообщалось	Не сообщается: оператор не указал газифицирован ли дом. в тексте: «Дом газифицирован.» подтвердить отклонить
не записано	В тексте оператора не указано место происшествия. услышано: «Нет, что вы, это Королёв, Московская область!» подтвердить отклонить
не записано	В тексте оператора не указан адрес происшествия. услышано: «Улица Станционная, 28.» подтвердить отклонить

Замечания модели балл не меняют. Модель ошибается, поэтому каждое замечание подтверждено цитатой и решение по нему за преподавателем.

«проверяется соответствие того, что было сообщено голосом с тем, что он заполнил в карточке, какие службы выбрал»
— сессия Q&A, чат № 642

Как сделано

- Правила: у каждого факта сценария — «выяснил» или «угадал»; службы сверяются с классификатором ЕКП
- Нейросеть читает описание курсанта против реплик заявителя: упущено, противоречит, добавлено от себя
- Цитату каждого замечания проверяет код — выдуманная отбрасывается
- Преподаватель подтверждает замечания и ставит экспертную оценку

Проверено на 66 парах «описание — факт»

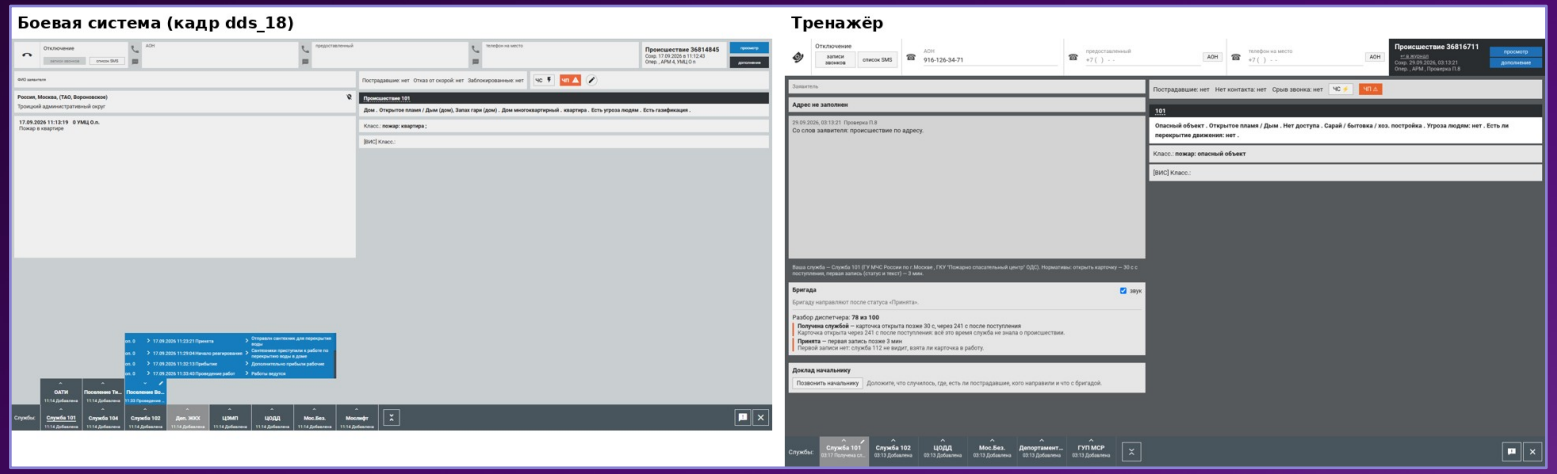
- **GPU, Gemma 4:** 94 %, 0,45 с на описание
- **CPU, кросс-энкодер OpenJEV 4B:** 91 %, 4,9 с
- **для сравнения GigaChat:** 73 % — не видит упущенного

Требование: ТЗ, постановка задачи — «оценка действий операторов на основе нейросетевого анализа», «анализ ручного ввода текста»; Q&A, чат № 642. Замер — backend/docs/замеры/ОПИСАНИЯ.md

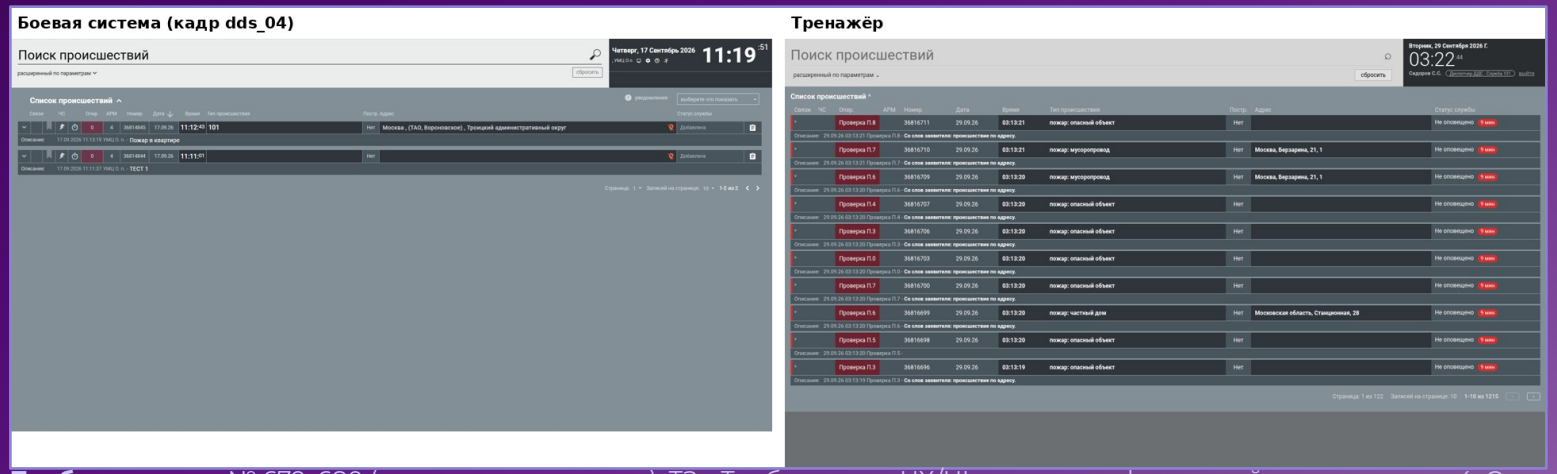
UX: КАК В БОЕВОЙ СИСТЕМЕ — 100 %

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Карточка ДДС: кадр боевой системы — экран тренажёра



Реестр происшествий: кадр боевой системы — экран тренажёра



«Карточка и реестр обращений 100% должны быть похожи»

— заказчик, чат № 680

Как сделано

- Журнал, карточка 112 и карточка ДДС сняты с кадров: сетка, цвета, полосы служб
- Справочники как в боевой: 211 служб в окне «Добавьте службы» — как на 55 кадрах; 51 тип «что случилось?» — написание и порядок по выпадающему списку
- Сравнения всех экранов с кадрами — docs/presentation/screens/audit/
- Узкий экран — без горизонтальной прокрутки (проверка e2e)

Требование: чат № 679, 680 (встреча с заказчиком); ТЗ, «Требования к UX/UI»; критерии финальной экспертизы, п. 4. Справочники — refs/СЛУЖБЫ 112.docx, КАРТОЧКА 112.docx; выписка по кадрам — backend/docs/справочники/

ДВЕ РОЛИ: ОПЕРАТОР 112 И ДИСПЕТЧЕР ДДС

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

«Один интерфейс, одна учетка, две мини роли… обучающего могут направить на практику в одно или другое место»
— организатор, чат № 624

Оператор 112

- Учебные вызовы: билеты и задания занятия
- Разговор с заявителем, карточка 112 и опросная карта
- Службы подбирает классификатор ЕКП, можно добавить вручную
- Свой разбор, прогноз, рекомендации
- Нет доступа: статусы, бригада, лента службы

Диспетчер ДДС

- Поток карточек своей службы
- Карточка ДДС: поля 112 — только чтение
- Статусы, бригада, доклады старшего, доклад начальнику
- Свой разбор ДДС
- Нет доступа: приём вызова 112 и заполнение карточки 112

Профиль назначает преподаватель или администратор — «направить на практику»; смена действует сразу. Права проверяет сервер: чужое действие — отказ с причиной, а не спрятанная кнопка.

Требование: чат № 624, 628 (разбор ролей с организатором); ТЗ, «Разграничение доступа к данным по ролям»

ПРОЦЕСС ДДС ПО ОТВЕТАМ ЗАКАЗЧИКА

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

30 с

от появления карточки в списке до её открытия — отметка «Получена службой»

3 мин

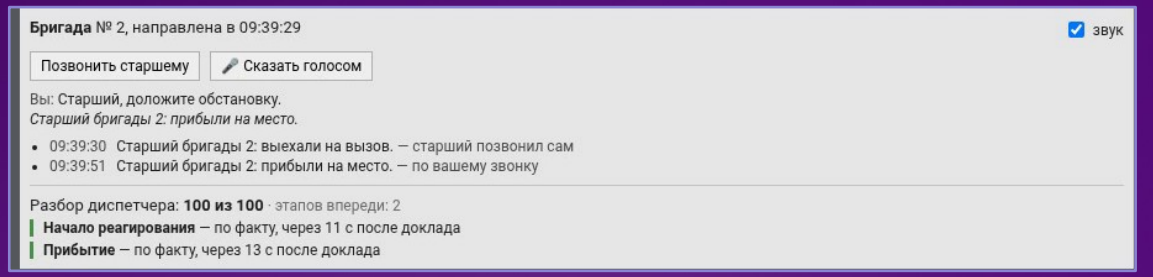
на первую запись: статус и текст

поток

карточки приходят, пока диспетчер занят; у ожидающих идёт своё время

7

статусов: принята, не принята, начало реагирования, прибытие, работы, завершение, отказ — отказ только с причиной



Панель бригады: доклад старшего, звонок, разбор

Бригада и разбор

- Бригаду диспетчер выбирает вручную, службы в карточку ДДС не добавляет
- Старший докладывает сам, или диспетчер звонит ему
- Статус засчитывается, только если поставлен по факту доклада
- Разбор: открыто вовремя, первая запись, статусы — с ценой ошибки

«30 сек при поступлении карточки... 3 минуты на открытие карточки и добавления первой записи. Статуса и текста»

— заказчик, чат № 781

«Одновременно, как в текущей работе... тайминг идёт и для этой работы и для тех карточек, что в очереди»

— организатор, чат № 709

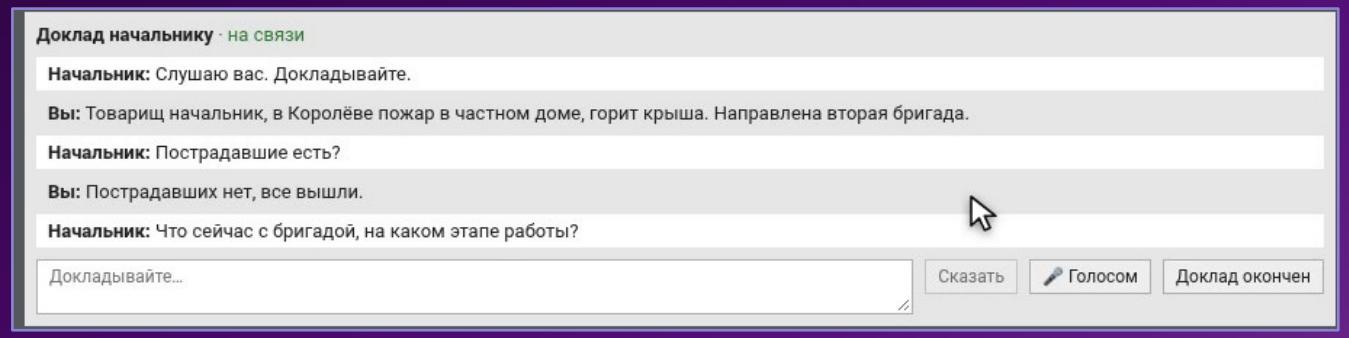
Требование: ответы заказчика в чате № 684 (бригады вручную), 691 (доклады старшего), 701 (службы не добавляются), 709 (поток), 781 (нормативы и статусы)

ГОЛОС: СТАРШИЙ БРИГАДЫ И НАЧАЛЬНИК

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

«голосовое общение ДДС с вышестоящим начальником и ДДС с руководителем бригады… Физический IP-телефон не обязателен, достаточно программной эмуляции»

— чат № 781: заказчик и организатор



Доклад начальнику: вопросы по недоложенному, кнопка «Голосом», затем разбор

Как сделано

- Речь курсанта распознаёт GigaAM-v3, ответы озвучивает TeraTTSv2
- Всё локально, на процессоре; без SIP — программная эмуляция
- Начальник спрашивает только о том, что есть в карточке

0,2–0,3 с
распознать фразу

0,5–0,7 с
озвучить фразу доклада

Разбор доклада начальнику: что доложено, что нет, что неверно — с цитатами, проверенными кодом; на GPU — 1,3 с. В телефонии заказчик ставил фокус на связи «ДДС — службы» (Q&A, № 638).

Требование: чат № 781; сессия Q&A, чат № 576, 638. Замеры — backend/docs/замеры/ГОЛОС.md, доклад-начальнику.md; процессор EPYC 7532, 4 потока

СВЕРХ MVP: РАЗГОВОР С ЗАЯВИТЕЛЕМ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

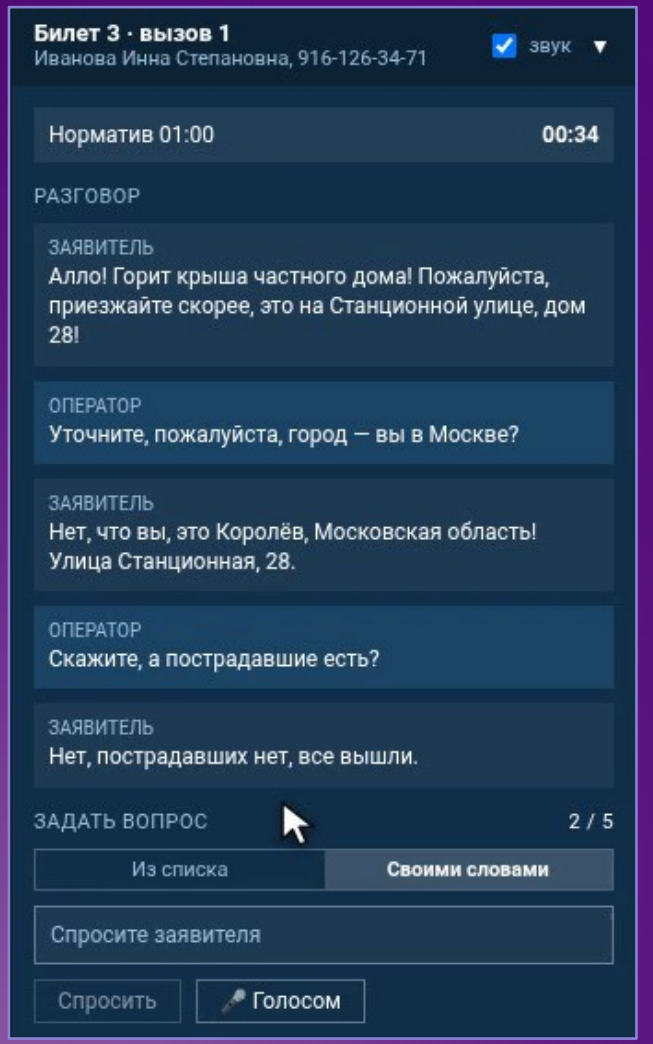
«Диалог с заявителем исключен на этапе MVP, но вы можете его сделать — это будет плюсом»
— заказчик, чат № 781

Вопрос своими словами

- Голосом или текстом, как в живом разговоре
- Модель выбирает факт из закрытого списка сценария — выдумать нечего
- Понято 27 из 27 вопросов
- Бессмысленные отсеяны: CPU — 5 из 7 за 1,7 с, GPU — 7 из 7 за 0,13 с

Заявитель отвечает голосом

- Мужской или женский голос — по отчеству
- На GPU — живая реплика модели: 16 из 19 живые, 0,5 с
- Реплику проверяют код и вторая модель; не прошла — фраза сценария
- «Выяснил / угадал» не зависит от генерации



Требование: чат № 781. Замеры — backend/docs/замеры/СВОБОДНЫЙ-ВОПРОС.md, ЖИВОЙ-ЗАЯВИТЕЛЬ.md

ПРОГНОЗ И ЕГО ДОСТОВЕРНОСТЬ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Как устроено

- Прогноз балла фиксируется до начала вызова — задним числом не правится
- Факт — после разбора; рядом всегда базовая линия: средний балл курсанта
- Модель — гребневая регрессия по истории курсанта: объяснимо, не переобучается

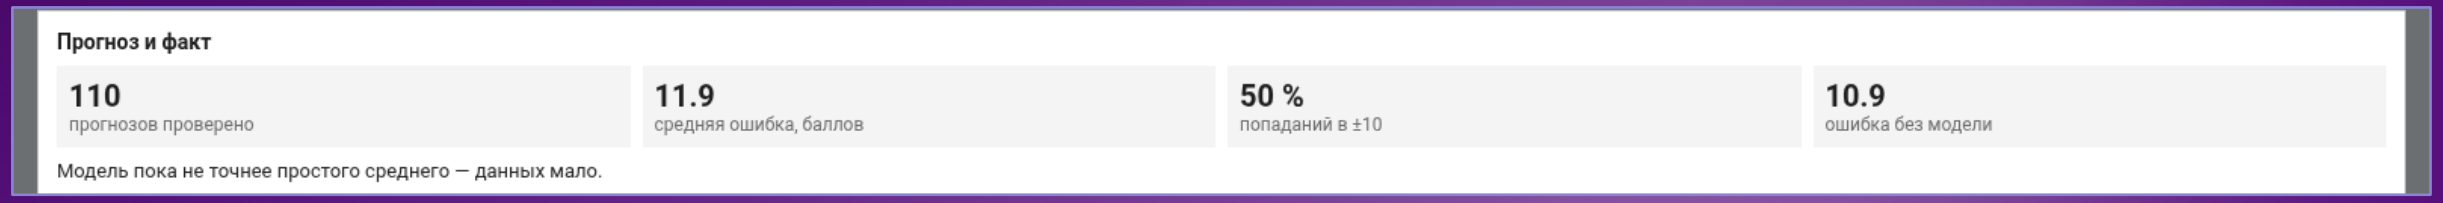
10,7
средняя ошибка прогноза, баллов

10,9
та же ошибка у базовой линии

56 %
прогнозов в допуске ±10

Честно: на малых данных модель почти не лучше простого среднего — и экран аналитики говорит это сам. Проверка — 110 прогнозов по 10 синтетическим курсантам через API, не реальная группа. Точнее станет с историей реальных курсантов и отбором проверочных попыток.

На снимке ниже — блок «Прогноз и факт» в аналитике преподавателя — на копии стенда, где история засорена автотестами: там модель хуже среднего — 11,9 против 10,9, и экран сам пишет «Модель пока не точнее простого среднего — данных мало».



Требование: критерии ТЗ: предварительная экспертиза, п. 3 — «проверка прогнозирования (оценка достоверности)»; финальная, п. 3 — «сравнение реальных данных и прогнозных значений». Замер — docs/АУДИТ-ПО-КРИТЕРИЯМ.md, прогноз-эксперимент.py

РЕКОМЕНДАЦИИ И ПРОВЕРКА ИХ ИСПОЛНЕНИЯ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Как устроено

- Рекомендация выдаётся, когда ошибка повторилась, — текст из замечаний разбора, модель его не пишет
- Фиксируется с временем; следующий разбор ставит вердикт: ушла ошибка или нет
- Рядом базовая линия: как часто та же ошибка уходит сама

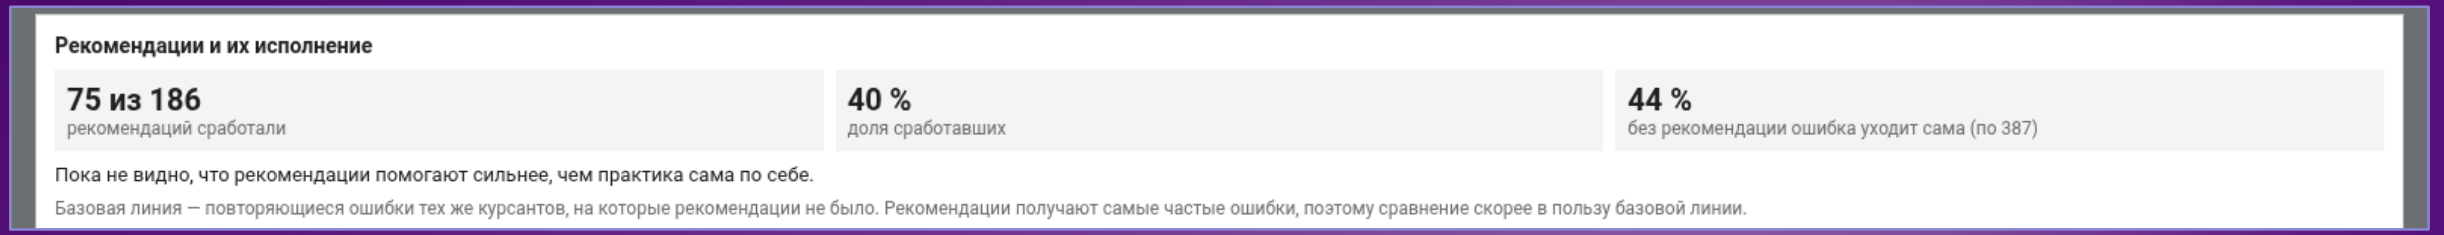
412
рекомендаций выдано

372
проверено следующим вызовом

40 %
из проверенных сработали

Честно: проверен механизм, а не польза — синтетические курсанты рекомендаций не читают. «Реальных рекомендаций» для сверки в материалах заказчика нет; на живой группе доля сработавших покажет пользу.

На снимке ниже — блок «Рекомендации и их исполнение» на той же копии стенда: сработали 40 %, а без рекомендации ошибка уходит сама в 44 % — и экран пишет «Пока не видно, что рекомендации помогают сильнее, чем практика сама по себе».



Требование: критерии финальной экспертизы ТЗ: п. 3 — «проверка рекомендаций сервиса и реальных рекомендаций»; п. 4 — «соответствие рекомендаций реальным при текущих вводных». Замер — docs/АУДИТ-ПО-КРИТЕРИЯМ.md

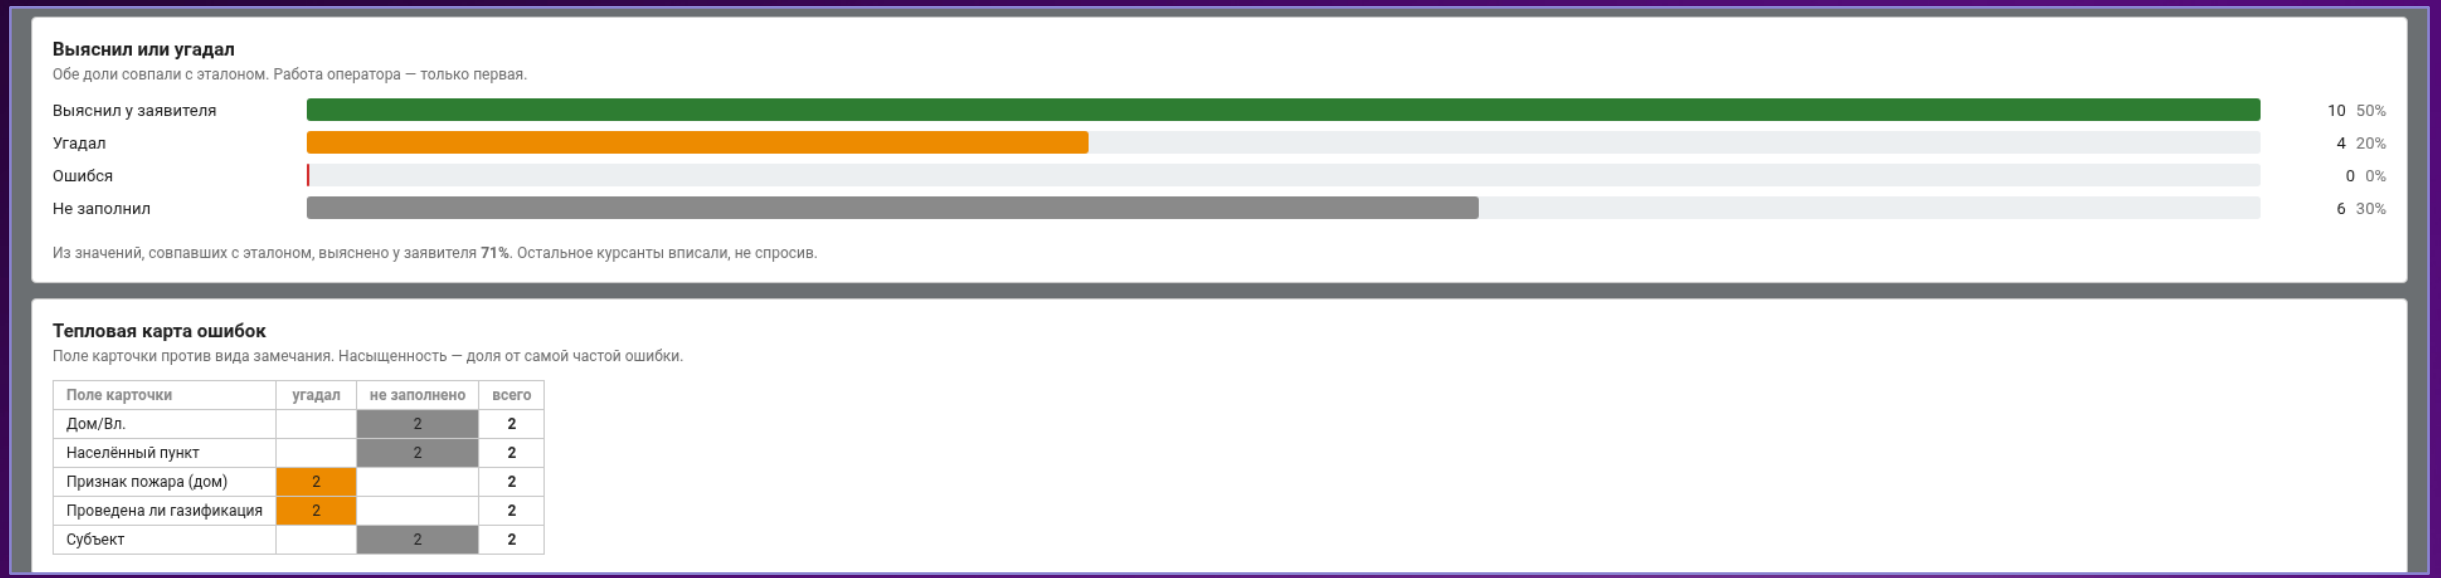
ДОПОЛНИТЕЛЬНЫЕ НАСТРАИВАЕМЫЕ ПАРАМЕТРЫ

Группа	Параметр	По умолчанию	Пределы
Нормативы ДДС	открыть карточку	30 с	5–600 с
	первая запись (статус и текст)	3 мин	10 с – 60 мин
	перевод в «Не завершено»	48 ч	1–720 ч
Занятие	интервал потока карточек ДДС	60 с	10–900 с
	марафон; блиц	—	5–10 вызовов; 3–10 заданий
Бригада	число бригад службы	3	1–10
	выезд, прибытие, начало работ, работы	20 / 40 / 20 / 60 с	5–3600 с
	задержка доклада; статус после доклада	25 с; 30 с	0–3600; 5–600 с
Прогноз	допуск попадания	±10 баллов	1–30
	глубина истории; регуляризация	5; 0,1	3–20; 0–10
Рекомендации	окно разборов	5	2–20
Аттестация	порог прохождения	70 баллов	1–100
ИИ	движок анализа текста	авто	авто / кросс-энкодер / LLM
	живые реплики начальника и заявителя	выкл. на CPU	вкл. / выкл.
	адреса моделей	локальные	ML_BASE_URL, VOICE_, NLI_BASE_URL

18 параметров — в таблице настроек, не в коде; значение вне пределов сервер отклоняет. Администратор меняет их на вкладке «Параметры» (или через API), каждое изменение — в журнале действий.

Требование: критерии финальной экспертизы ТЗ, п. 3 — «реализация дополнительных настраиваемых параметров»; ТЗ, роль преподавателя — «настраивать критерии успешности»

ДИАГРАММЫ ИЗ РЕАЛЬНЫХ ДАННЫХ



Почему им можно верить

- Строятся из статистики занятий, без сторонних библиотек
- Каждая доля — с числителем и знаменателем («4 из 14»)
- Словесную сводку пишет модель, но числа ей подаются уже посчитанными

Что на экране аналитики

- Выяснил или угадал; тепловая карта ошибок; время против норматива
- Прогноз и рекомендации — рядом с базовой линией
- Честно: проверочные прогоны от учебных попыток пока не отделяются — на чистой базе стенда их нет; отбор — в планах

Требование: критерии финальной экспертизы ТЗ, п. 3 — «проверка объективности диаграмм… визуальная восприимчивость и отражение данных»; ТЗ, опционально — «тепловые карты ошибок»

ПРЕПОДАВАТЕЛЬ И АДМИНИСТРАТОР

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Преподаватель

- Модель готовит учебные вызовы из билетов, правка — перепиской; курсанты видят вызов только после утверждения
- Занятия 112 и ДДС; марафон — экзамен из 5–10 вызовов; блиц — одна часть карточки
- Автоматическая и экспертная оценка рядом; подтверждение или отклонение замечаний нейросети, комментарий курсанту
- Аналитика группы; назначение курсанта на рабочее место

Администратор

- Учётные записи и рабочие места курсантов
- Блокировка сразу отзывает вход
- Удаление — сначала резервная копия, затем обезличивание; оценки остаются
- Журнал действий, ежесуточные копии базы, состояние сервера
- Экспертных оценок не ставит — это право преподавателя

«Дообучать модель» по поправкам преподавателя — честно: правки идут в сценарий и в контекст модели при следующей подготовке, веса не меняются. Как должны вноситься поправки, заказчик переспросил в том же ответе (чат № 781).

Требование: ТЗ, роли преподавателя и администратора: «автоматическая оценка И экспертная оценка», «запрет изменения оценок во время активного занятия»; чат № 781

ЗАКРЫТЫЙ КОНТУР И ЖЕЛЕЗО ИЗ ТЗ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

«в самом решении должна быть возможность прописать, куда обращаться к модели, если она будет не во вне, а локально»
— организатор, чат № 746

	CPU — как в ТЗ: i7/Xeon от 6 ядер, 32 ГБ	**GPU — если заказчик выделит**
Языковая модель	GigaChat 3.1 10B-A1.8B, llama.cpp + MTP	Gemma 4 26B-A4B, INT4, vLLM, одна RTX 4090
Сверка описания с фактами	кросс-энкодер OpenJEV 4B, 91 %	Gemma 4, 94 %
Голос	GigaAM-v3 и TeraTTSv2 на процессоре	то же
Живые реплики начальника и заявителя	выключены — медленно	включены; реплика заявителя 0,5 с

Внешних обращений нет. Все модели работают внутри контура; адрес каждой — одна переменная (ML_BASE_URL, VOICE_BASE_URL, NLI_BASE_URL).

Развёртывание одной командой deploy/up.sh (docker compose), HTTPS — браузер даёт микрофон только защищённой странице.

Честно о замерах: CPU мерили на EPYC 7532 (6 потоков, 8 каналов памяти) — это потолок; на настольном i7 будет медленнее, там не мерили.

Требование: ТЗ — «без доступа к внешним сетям», системные требования к серверу ИИ; чат № 710, 746 (адрес локальной модели), 23.09 (видеокарта — «если нужно будет»)

СКОРОСТЬ РАБОТЫ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Задача	CPU: GigaChat 3.1	GPU: Gemma 4
Генерация, токенов в секунду	14,8	170
Подготовка учебного вызова по билету	94 с	3 с
Анализ описания курсанта с цитатами	26–33 с	2,3 с
Разбор доклада начальнику	20,8 с	1,3 с
Сверка описания с фактами	4,9 с (кросс-энкодер)	0,45 с
Понять вопрос заявителю своими словами	1,7 с	0,13 с

+44 %

скорость GigaChat на процессоре от MTP — поддержку добавили в llama.cpp сами

сразу

разбор правилами — модель интерфейс не держит, анализ приходит следом

p99 0,27 с

отклик интерфейса при 100 пользователях

Требование: критерии ТЗ: п. 2 — «скорость работы решения»; финальная, п. 3 — «скорость и удобство работы». Замеры — сопроводительная документация, 6.2–6.3

НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ ТЗ — ИЗМЕРЕНО

Требование ТЗ	Измерено
Отклик интерфейса ≤ 2 с при 100 пользователях	максимум 0,69 с, p99 0,18 с; без пауз, 1783 запроса/с — p99 0,27 с
Не менее 20 одновременных сессий	50 вызовов разом — все дошли до разбора; 80 разом — все, до 2,2 с на вызов
Сбой сети до 30 с без потери данных	правки без сети — в базе через 0,1 с после её возврата; канал событий — сразу
Запись в БД ≥ 100 операций/с	1516 правок карточки в секунду, p99 41 мс
Отчёт ≤ 30 с	по группе 0,56–0,71 с, и 0,65 с при 176 задачах модели в очереди; по вызову 7–11 мс
Резервное копирование раз в сутки	ежесуточная копия базы с ротацией
Передача голоса ≤ 150 мс	не мерили: SIP нет, программная эмуляция — заказчик: «достаточно»

Сервер и база ограничены 6 ядрами и 32 ГБ, как сервер из ТЗ; процессор — EPYC 7532, не машина заказчика. Замеры нашли четыре узких места, в том числе отчёт в очереди за моделью, — исправлены до сдачи.

Требование: ТЗ, раздел нефункциональных требований (§7); чат № 781 (телефония — программная эмуляция). Методика и сырые данные — backend/docs/замеры/НАГРУЗКА.md

ИНТЕГРАЦИЯ В ДРУГИЕ СИСТЕМЫ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Открытый API

- REST, 75 операций
- Описание OpenAPI — /api/docs
- Тест сверяет описание с кодом

Модели по стандарту

- Протокол OpenAI: llama.cpp, vLLM, Ollama — без правки кода
- Голос и сверка — отдельные HTTP-сервисы

Данные заказчика

- Классификатор ЕКП грузится из XLSX как есть
- Версии классификатора и разница между ними — через API
- Службы и типы — по кадрам ваших материалов

Выгрузка

- Отчёт по вызову — JSON и CSV
- Отчёт по группе — JSON

Развёртывание

- docker compose, одна команда
- Свой сертификат или самоподписанный

Честно

- Вход — свои учётные записи; локальная система доступа (LDAP/AD) не подключена

Требование: критерии ТЗ, п. 2 — «возможность интеграции в любые другие системы»; ТЗ — «отдельный сервис», «интеграция с форматами данных ГБУ „Система 112“»

КАЧЕСТВО КОДА И ДОКУМЕНТАЦИЯ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

364
серверных теста — все зелёные; ещё 3 на настоящих моделях

80
сценариев в браузере (Playwright)

21,5 тыс.
строк Rust + 8,9 тыс. строк тестов

8 тыс.
строк TypeScript, React 19

Как пишем

- Тесты на отдельной базе — стенд не засоряется
- Описание API сверяется с кодом тестом
- Комментарии объясняют «почему», а не «что»
- 35 миграций базы, без ручных правок схемы
- Открытый код без обфускации

Что приложено

- Сопроводительная документация — PDF и DOCX: методы, ограничения, сборка, архитектура
- PROVENANCE.md — откуда каждый справочник и каждая цифра
- OPEN-QUESTIONS.md — все допущения и чего не хватило
- backend/docs/замеры — методика и сырые данные замеров

Требование: критерии ТЗ: п. 2 — «качество кода»; п. 4 — «полнота сопроводительной документации»; ТЗ — открытый код, перечень библиотек, комментарии к сложному

ОГРАНИЧЕНИЯ — ЧЕСТНО

Службы только по типу происшествия. Заказчик: службы ещё и по району и подчинённости, но «справочников нет в природе» (чат № 690, 781).

Веса модели не дообучаются. Правки преподавателя идут в сценарий и контекст; механизм поправок заказчик уточняет (чат № 781).

Скорость на i7 не мерили. CPU-замеры — на EPYC 7532 с 8 каналами памяти.

Эталонная версия классификатора не определена. v046_24 или v046_11 — заказчик обещал ответить; активна v046_24.

ДДС не сообщает в 112 об ошибке в карточке. Эталонных примеров ошибок заказчик не дал.

Прогноз и рекомендации проверены на синтетике. Прогноз пока ≈ простому среднему (10,7 против 10,9); польза рекомендаций не доказана — нужна живая группа.

Требование: чат № 690, 781; OPEN-QUESTIONS.md — полный список допущений

ПРОВЕРИТЬ САМИМ

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Ссылки

- Репозиторий: [ЗАПОЛНИТЬ: ссылка]
- Стенд: [ЗАПОЛНИТЬ: ссылка]
- Документация: docs/документация.pdf
- Демо-ролик: [ЗАПОЛНИТЬ: ссылка]

Учётные записи, пароль arm112

- admin — администратор
- teacher1 — преподаватель
- student1 — оператор 112
- student3 — диспетчер ДДС, Служба 101

Дальше: подбор служб по территории — после справочника заказчика; сверка анализа нейросети с оценками преподавателей на живой группе; SIP-телефония.